



วิทยานิพนธ์

ปัจจัยที่ส่งผลต่อผลลัพธ์การรักษามะเร็งกระดูก

FACTORS INFLUENCING TREATMENT OUTCOMES IN BONE CANCER

นางสาวณัฐนิชา เมืองมูล

บัณฑิตวิทยาลัย มหาวิทยาลัยเกษตรศาสตร์

ปีการศึกษา ๒๕๖๘



460115265

KU iThesis 6514401007 thesis / recv: 20052569 22:51:00 / seq: 158



6514401007_460115265

ใบรับรองวิทยานิพนธ์

บัณฑิตวิทยาลัย มหาวิทยาลัยเกษตรศาสตร์

ปริญญา วิทยาศาสตรมหาบัณฑิต (วิทยาศาสตร์ข้อมูลชีวการแพทย์)

สาขาวิชา วิทยาศาสตร์ข้อมูลชีวการแพทย์

คณะ วิทยาศาสตร์

เรื่อง ปัจจัยที่ส่งผลต่อผลลัพธ์การรักษามะเร็งกระดูก

Factors Influencing Treatment Outcomes in Bone Cancer

นามผู้วิจัย นางสาวณัฐธิดา เมืองมูล

ได้พิจารณาเห็นชอบโดย

อาจารย์ที่ปรึกษาวิทยานิพนธ์หลัก

(รองศาสตราจารย์จุฑาภรณ์ สันสมบุรณ์ทอง, ปร.ค.)

อาจารย์ที่ปรึกษาวิทยานิพนธ์ร่วม

(ผู้ช่วยศาสตราจารย์ผกาเกษ วัฒนา, Dr.rer.nat.)

ประธานสาขาวิชา

(รองศาสตราจารย์ลีลี อิงศรีสว่าง, Ph.D.)

บัณฑิตวิทยาลัย มหาวิทยาลัยเกษตรศาสตร์รับรองแล้ว

(รองศาสตราจารย์วิระภาส คุณรัตนศิริ, Dr.rer.nat.)

คณบดีบัณฑิตวิทยาลัย



460115265

KU lThesis 6514401007 thesis / recv: 20052569 22:51:00 / seq: 158

วิทยานิพนธ์

เรื่อง

ปัจจัยที่ส่งผลต่อผลลัพธ์การรักษามะเร็งกระดูก

Factors Influencing Treatment Outcomes in Bone Cancer

โดย

นางสาวณัฐนิชา เมืองมูล

เสนอ

บัณฑิตวิทยาลัย มหาวิทยาลัยเกษตรศาสตร์

เพื่อความสมบูรณ์แห่งปริญญาวิทยาศาสตรมหาบัณฑิต (วิทยาศาสตรข้อมูลชีวการแพทย์)

ปีการศึกษา 2568



460115265

KU lThesis 6514401007 thesis / recv: 20052569 22:51:00 / seq: 158

ณัฐธินิชา เมืองมูล : ปัจจัยที่ส่งผลต่อผลลัพธ์การรักษามะเร็งกระดุก ปริญญาวิทยาศาสตร
มหาบัณฑิต (วิทยาศาสตรข้อมูลชีวการแพทย์) สาขาวิชาวิทยาศาสตรข้อมูลชีวการแพทย์ คณะ
วิทยาศาสตร
อาจารย์ที่ปรึกษาวิทยานิพนธ์หลัก: รองศาสตราจารย์จุฑาภรณ์ ลินสมบูรณ์ทอง, ปร.ด.
ปีการศึกษา 2568

งานวิจัยนี้มีวัตถุประสงค์เพื่อสร้างตัวแบบและปัจจัยที่ส่งผลต่อผลลัพธ์การรักษา
มะเร็งกระดุก 5 วิธี ได้แก่ ตัวแบบการถดถอยโลจิสติก (Logistic Regression), ตัวแบบการสุ่มป่า
ไม้ (Random Forest), ตัวแบบโครงข่ายประสาทเทียม (Artificial Neural Network), Support
Vector Machine (SVM) และ K-Nearest Neighbors (KNN) โดยใช้ข้อมูลจาก Memorial Sloan
Kettering Cancer Center (MSKCC) เป็นชุดข้อมูลที่มีการเปิดเผยแหล่งข้อมูลจำนวน 500 เรคค
อर्ड ข้อมูลที่ศึกษาประกอบไปด้วยตัวแปรตาม คือ สถานะของผู้ป่วย และ ตัวแปรอิสระ 7 ตัว
ได้แก่ เพศ, อายุ, ระดับความรุนแรงของเนื้องอก, ประเภทเนื้องอกกระดุกทางพยาธิสภาพ, การ
แบ่งเนื้องอกกระดุกโดย MSKCC, ตำแหน่งของเนื้องอกกระดุก และวิธีการรักษา

ผลการศึกษาพบว่าทั้ง 7 ตัวแปรส่งผลต่อผลลัพธ์การรักษามะเร็งกระดุกโดยวิธีการ
รักษามีอิทธิพลต่อสถานะของผู้ป่วยมากที่สุด ซึ่งมีผลสอดคล้องกับการทำนายของตัวแบบทั้ง
4 ตัวแบบ ซึ่งโครงข่ายประสาทเทียม (Artificial Neural Network) มีประสิทธิภาพในการทำนาย
แม่นยำที่สุดร้อยละ 81

ลายมือชื่อนิติ

ลายมือชื่ออาจารย์ที่ปรึกษาวิทยานิพนธ์หลัก

____ / ____ / ____

Nuttanicha Muangmool : Factors Influencing Treatment Outcomes in Bone Cancer. Master of Science (Biomedical Data Science), Major Field: Biomedical Data Science, Faculty of Science. Thesis Advisor: Associate Professor Juthaphorn Sinsomboonthong, Ph.D.
Academic Year 2025

The research was conducted to create models and study factors factors influencing treatment outcomes in bone cancer. Five methods: Logistic Regression, Random Forest, Artificial Neural Network (ANN), Support Vector Machine (SVM), and K-Nearest Neighbors (KNN) were applied. A dataset containing 500 records was obtained from the open-source database of the Memorial Sloan Kettering Cancer Center (MSKCC). The dependent variable was defined as the status of patients, while seven independent variables were included: Sex, Age, grade, Histological type, MSKCC type, Site of primary STS, and Treatment.

The study's results revealed that all seven variables influenced the status of patients with bone cancer. The treatment tended to be the most significant impact, and this conformed with four methods. In addition, the Artificial Neural Network model tended to have the highest prediction accuracy of 81%.

Student's signature

Thesis Advisor's signature

____/____/____

กิตติกรรมประกาศ

ผู้จัดทำขอขอบคุณ Mr. Albert Antony และ Memorial Sloan Kettering Cancer Center (MSKCC) ที่เผยแพร่ข้อมูลรวมถึง รศ.ดร. จุฑาภรณ์ สีนสมบูรณ์ทอง เป็นอาจารย์ที่ปรึกษาวิทยานิพนธ์หลักและ ผศ.ดร. ผกาเกษ วัฒนา เป็นอาจารย์ที่ปรึกษาวิทยานิพนธ์ร่วมและคณาจารย์ประจำหลักสูตรวิทยาศาสตรบัณฑิตข้อมูลชีวการแพทย์ คณะวิทยาศาสตร์ มหาวิทยาลัยเกษตรศาสตร์ที่ให้คำแนะนำและข้อเสนอแนะในการทำวิจัยจนเสร็จสมบูรณ์

ณัฐธินิชา เมืองมูล

สารบัญ

หน้า

บทคัดย่อภาษาไทย	ก
บทคัดย่อภาษาอังกฤษ	ง
กิตติกรรมประกาศ	จ
สารบัญ	ฉ
สารบัญตาราง	ซ
สารบัญภาพ	ฌ
คำนำ	1
วัตถุประสงค์	2
สมมติฐาน	2
ขอบเขตงานวิจัย	3
ประโยชน์ที่คาดว่าจะได้รับ	3
การตรวจเอกสาร	3
ทฤษฎีที่เกี่ยวข้อง	3
1. มะเร็งกระดูก (Bone Cancer)	3
2. ชนิดของมะเร็งกระดูก	5
3. สาเหตุที่เป็นไปได้ของมะเร็งกระดูก	6
4. ตัวแปรเป้าหมายและปัจจัยที่ส่งผลต่อผลลัพธ์การรักษามะเร็งกระดูก	8
5. วิธีการแก้ปัญหาข้อมูลไม่สมดุล	14
6. ตัวแบบสำหรับการทำนาย	20
7. Feature Importance	30
8. Permutation Importance	31

9. เมทริกซ์สหสัมพันธ์ (Correlation Matrix)	31
10. การทดสอบไคสแควร์ (Chi-square test).....	31
11. เกณฑ์ที่ใช้ในการเปรียบเทียบประสิทธิภาพของตัวแบบ	33
งานวิจัยที่เกี่ยวข้อง	34
อุปกรณ์และวิธีการ	38
1. วัสดุและอุปกรณ์	38
2. วิธีการดำเนินการ	38
ผลการวิจัย	46
1. ผลจากการวิเคราะห์ข้อมูลเชิงสำรวจ	46
2. ผลการวิเคราะห์ของตัวแบบ.....	50
3. วิจัย	58
สรุปผลการทดลอง	59
ข้อเสนอแนะ.....	60
เอกสารและสิ่งอ้างอิง.....	61
ภาคผนวก	67
ประวัติการศึกษา และการทำงาน	87

สารบัญตาราง

หน้า

ตารางที่ 1 การแบ่ง Histological type ของชุดข้อมูล ตาม WHO Classification of Tumours of Soft Tissue and Bone 2020	9
ตารางที่ 2 แสดงลักษณะและรายละเอียดของตัวแปร	40
ตารางที่ 3 ผลการแสดงความสัมพันธ์ระหว่างตัวแปรเชิงกลุ่มและการทดสอบความสัมพันธ์ระหว่างตัวแปรอิสระกับสถานะผู้ป่วยด้วยสถิติทดสอบ Chi-square และ Correlation Matrix ($r_{y,xi}$)	47
ตารางที่ 4 ผลการทดสอบประสิทธิภาพของ Logistic Regression	53
ตารางที่ 5 ผลการทดสอบประสิทธิภาพของ Random Forest	54
ตารางที่ 6 ผลการทดสอบประสิทธิภาพของ Support Vector Machine	54
ตารางที่ 7 ผลการทดสอบประสิทธิภาพของ Artificial Neural Network	55
ตารางที่ 8 ผลการทดสอบประสิทธิภาพของ K-Nearest Neighbors	55
ตารางที่ 9 ตารางแสดงร้อยละของวิธีการรักษากับสถานะของผู้ป่วย	57
ตารางที่ 10 ตารางแสดงค่าวัดประสิทธิภาพของแต่ละตัวแบบ	60



สารบัญภาพ

	หน้า
ภาพที่ 1 Bone Tumors	4
ภาพที่ 2 Random Undersampling.....	15
ภาพที่ 3 Tomek Links	16
ภาพที่ 4 NearMiss	18
ภาพที่ 5 Edited Nearest Neighbors (ENN).....	19
ภาพที่ 6 Random Forest	21
ภาพที่ 7 Artificial neural network (ANN).....	27
ภาพที่ 8 การนำข้อมูลเข้า Jupyter Notebook.....	38
ภาพที่ 9 ภาพรวมชุดข้อมูล	39
ภาพที่ 10 การแปลงข้อมูลจากข้อความเป็นตัวเลข.....	39
ภาพที่ 11 ความสัมพันธ์ของตัวแปรตาม (Y) และ ตัวแปรอิสระ (Xi) โดย Chi-square.....	42
ภาพที่ 12 เมตริกซ์สหสัมพันธ์.....	43
ภาพที่ 13 ระบุตัวแปร	43
ภาพที่ 14 การแบ่งตัวแปรอิสระ(X_i).....	44
ภาพที่ 15 การแบ่งตัวแปรตาม (Y).....	44
ภาพที่ 16 แผนภาพการดำเนินงาน	45
ภาพที่ 17 กราฟตรวจสอบค่า Outliers ของอายุ	46
ภาพที่ 18 กราฟแสดงความสัมพันธ์ระหว่างตัวแปรอิสระกับสถานะผู้ป่วย.....	50
ภาพที่ 19 Feature Importance ของตัวแบบทั้ง 5 วิธี.....	51
ภาพที่ 20 ตัวอย่างตัวแบบการทำนาย Random Forest	52
ภาพที่ 21 ROC AUC ของตัวแบบทั้ง 5 วิธี	56



ภาพที่ 22 กราฟแสดงร้อยละของวิธีการรักษากับผลการรักษาของผู้ป่วย	57
ภาพที่ 23 Permutation Feature Importance ของวิธีการรักษากับสถานะของผู้ป่วย	58



460115265

KU lThesis 6514401007 thesis / recv: 20052569 22:51:00 / seq: 158

คำนำ

มะเร็งกระดูก (Bone Cancer) คือมะเร็งที่เริ่มต้นในกระดูกหรือแพร่กระจายมายังกระดูก มะเร็งกระดูกสามารถเกิดขึ้นได้กับกระดูกมากกว่า 200 ชิ้นในร่างกาย แม้ว่ากระดูกบางตำแหน่งจะพบได้บ่อยกว่าตำแหน่งอื่น มะเร็งกระดูกสามารถเกิดได้ทั้งในผู้ใหญ่และเด็ก มะเร็งกระดูกสามารถแบ่งออกเป็น 2 ชนิด ได้แก่ มะเร็งกระดูกปฐมภูมิ (Primary Bone Cancer) และมะเร็งกระดูกทุติยภูมิ (Secondary Bone Cancer) มะเร็งกระดูกปฐมภูมิเริ่มต้นจากภายในกระดูกและเป็นมะเร็งที่พบได้ไม่บ่อย เซลล์มะเร็งสามารถเจริญเติบโตบนผิวกระดูก ชั้นนอกของกระดูก หรือบริเวณกึ่งกลางกระดูก และจะค่อย ๆ ทำลายเนื้อกระดูกปกติ รวมทั้งสามารถแพร่กระจายไปยังส่วนอื่นของร่างกายได้ มะเร็งกระดูกปฐมภูมิบางครั้งเรียกว่า ซาร์โคมากระดูก อีกชนิดคือ (Bone Sarcoma) มะเร็งกระดูกทุติยภูมิคือมะเร็งที่เริ่มต้นจากอวัยวะส่วนอื่นของร่างกายแล้วแพร่กระจายมายังกระดูก ซึ่งพบได้บ่อยกว่ามะเร็งกระดูกปฐมภูมิ มะเร็งทุกชนิดสามารถแพร่กระจายมายังกระดูกได้ แต่ชนิดที่พบได้บ่อย ได้แก่ มะเร็งเต้านม มะเร็งปอด มะเร็งไต มะเร็งต่อมไทรอยด์ มะเร็งต่อมลูกหมาก รวมถึงมัยอิโดมา (Myeloma) และเมลาโนมา (Melanoma) มะเร็งกระดูกทุติยภูมิมักพบบริเวณกระดูกสะโพก กระดูกต้นขา กระดูกหัวไหล่ หรือกระดูกสันหลัง (Australia, 2023) มะเร็งกระดูกปฐมภูมิถูกรวมอยู่ในหมวดหมู่ที่กว้างจากการค้นคว้าหาข้อมูลได้มีการบอกว่า ประเภทพยาธิวิทยาของเนื้องอก (Histological type) โดยจากชุดข้อมูลถ้าแบ่งตาม WHO Classification of Tumours of Soft Tissue and Bone 2020 จะแบ่งออกมาได้ 5 กลุ่ม ได้แก่ Smooth Muscle Tumours เป็นกลุ่มที่มีความแตกต่างทางกล้ามเนื้อเรียบ, Synovial Sarcoma เป็นกลุ่มเฉพาะ, Fibroblastic and Myofibroblastic Tumours มีความแตกต่างทาง Fibroblast หรือ Myofibroblast, Liposarcoma มีความแตกต่างทาง Adipocytic Tissue ไขมัน, Undifferentiated Pleomorphic Sarcoma (UPS) เป็นกลุ่มที่ไม่สามารถระบุความแตกต่างชัดเจน (Board, 2020) มักจะส่งผลกระทบต่อผลลัพธ์หลังการรักษา (Lucas et al., 2008) และลักษณะทางเนื้อเยื่อที่มีความสำคัญต่อการทำนายการรอดชีวิตและผลลัพธ์ของการรักษาในผู้ป่วย มะเร็งกระดูกที่ได้รับเคมีบำบัดก่อนการผ่าตัด ผลการวิจัยพบว่าปัจจัยสำคัญ ได้แก่ อัตราการตายของเนื้องอก การตอบสนองทางเนื้อเยื่อวิทยา ขนาดของเนื้องอก และระยะทางคลินิก มีความสัมพันธ์อย่างมีนัยสำคัญกับผลลัพธ์ของผู้ป่วย (Vangala et al., 2021) และวิธีการรักษา (Treatment) เช่น การผ่าตัด (Surgery), การฉายรังสี (Radiotherapy) และ เคมีบำบัด (Chemotherapy) โดยที่การผ่าตัดเป็นวิธีการรักษาหลักสำหรับมะเร็งกระดูก ในขณะที่เคมีบำบัดช่วยเพิ่มอัตราการรอดชีวิต และการฉายรังสีช่วยควบคุมการเจริญเติบโตของเนื้องอกในบริเวณนั้นและลดโอกาสการกลับมาเป็นซ้ำ การรักษาแบบหลายวิธีร่วมกันส่งสถานะของผู้ป่วย (Ramey et al, 2018)



การวิจัยในครั้งนี้ผู้วิจัยสนใจศึกษาปัจจัยที่ส่งผลต่อผลลัพธ์การรักษามะเร็งกระดุก 7 ปัจจัย ได้แก่ Sex, Age, Grade, Histological type, MSKCC type, Site of Primary STS, and Treatment เพื่อให้สามารถวางแผนการรักษาที่เหมาะสมในอนาคต การเข้าใจความสัมพันธ์ระหว่างปัจจัยเหล่านี้กับ Status (NED, AWD, D) จะช่วยลดอัตราการตาย (Dead: D)ของผู้ป่วยหรือเพิ่มอัตราการหายขาด (No evidence of disease: NED) จากโรคได้ โดยใช้วิธีการศึกษาความสัมพันธ์ระหว่างตัวแปรในครั้งนี้ได้แก่ เมทริกซ์สหสัมพันธ์ และ Feature Importance และได้ใช้วิธีการเปรียบเทียบประสิทธิภาพของแบบจำลองทั้ง 5 โดยมี ตัวแบบการถดถอยโลจิสติก (Logistic Regression), ตัวแบบการสุ่มป่าไม้ (Random Forest), ตัวแบบโครงข่ายประสาทเทียม (Neural Network), Support Vector Machine (SVM) และ K-Nearest Neighbors (KNN) เปรียบเทียบประสิทธิภาพของตัวแบบ คือ ความถูกต้อง (Precision), ความครอบคลุม (Recall), F1 Score, ความแม่นยำ (Accuracy) และ ROC AUC ประสิทธิภาพของตัวแบบถูกประเมินโดยใช้ค่า Training Accuracy, Test Accuracy และค่าเฉลี่ยของ cross-validation โดยพบว่าค่าความแม่นยำทั้งสามมีค่าสูงและใกล้เคียงกัน ซึ่งแสดงถึงความสามารถของแบบจำลองในการทั่วไป (Generalization) ได้ดี และไม่พบสัญญาณของปัญหา Overfitting หรือ underfitting หาก Training Accuracy และ Validation accuracy (Cross-Validation) ต่ำ แสดงว่าแบบจำลองนั้น Underfitting สะท้อนว่าแบบจำลองไม่สามารถเรียนรู้รูปแบบของข้อมูลได้อย่างเพียงพอ หากความ Training Accuracy สูงแต่ Validation Accuracy หรือ Test Accuracy ต่ำกว่ามาก แสดงว่าแบบจำลองนั้น Overfitting สะท้อนว่าแบบจำลองเรียนรู้ข้อมูลฝึกมากเกินไปและไม่สามารถนำไปใช้กับข้อมูลใหม่ได้ (Hastie et al, 2009; Géron, 2019)

วัตถุประสงค์

1. เพื่อศึกษาปัจจัยที่ส่งผลต่อผลลัพธ์การรักษามะเร็งกระดุก
2. เพื่อเปรียบเทียบประสิทธิภาพของตัวแบบในการทำนายปัจจัยที่ส่งผลต่อผลลัพธ์การรักษามะเร็งกระดุก

สมมติฐาน

1. ตัวแบบที่มีความถูกต้องในการทำนายปัจจัยที่ส่งผลต่อผลลัพธ์การรักษามะเร็งกระดุกมากที่สุดคือ Artificial Neural Network

2. ปัจจัยที่ส่งผลกระทบต่อผลลัพธ์การรักษามะเร็งกระดูกมากที่สุดคือ Treatment และ Histological type

ขอบเขตงานวิจัย

ข้อมูลที่ใช้ในการสร้างตัวแบบเป็นข้อมูลทุติยภูมิของ Albert Antony จากเว็บไซต์ <https://www.kaggle.com> เป็นชุดข้อมูลของ Memorial Sloan Kettering Cancer Center (MSKCC) ซึ่งมีชุดข้อมูลชื่อว่า Bone Tumor มีจำนวน 500 เรคคอร์ด

ประโยชน์ที่คาดว่าจะได้รับ

1. ได้ตัวแบบที่ใช้ในการทำนายปัจจัยที่ส่งผลกระทบต่อผลลัพธ์การรักษามะเร็งกระดูก
2. ทราบปัจจัยที่ส่งผลกระทบต่อผลลัพธ์การรักษามะเร็งกระดูก

การตรวจเอกสาร

การตรวจเอกสารสำหรับงานวิจัยนี้แบ่งออกเป็น 2 ส่วน ส่วนแรกเป็นทฤษฎีที่เกี่ยวข้องและส่วนที่สองเป็นผลงานวิจัยที่เกี่ยวข้อง


ทฤษฎีที่เกี่ยวข้อง

1. มะเร็งกระดูก (Bone Cancer)

มะเร็งกระดูกเป็นมะเร็งที่มาจากเนื้องอกหลายชนิดสามารถเติบโตในกระดูก เนื้องอกในกระดูกก่อตัวจากเนื้อเยื่อกระดูกและอาจเนื้องอกมะเร็ง (Malignant), ไม่เป็นมะเร็ง (Benign) และเนื้องอกระยะแพร่กระจาย (Metastatic) เป็นเนื้องอกที่พัฒนาจากเซลล์มะเร็งที่ก่อตัวที่อื่นในร่างกายแล้วแพร่กระจายมายังกระดูก

BONE TUMORS

* BONE CELL DIVIDES UNCONTROLLABLY → FORMS TUMOR



ภาพที่ 1 Bone Tumors

ที่มา : Osmosis from Elseiver (2019)

เนื้องอกมะเร็ง (Malignant) หรือมะเร็งกระดูกปฐมภูมิพบได้น้อยกว่าเนื้องอกที่ไม่เป็นมะเร็งเนื้องอกทั้งสองชนิดอาจเจริญเติบโตและกดเบียดเนื้อกระดูกที่แข็งแรงได้ แต่เนื้องอกชนิดไม่ร้ายโดยทั่วไปจะไม่แพร่กระจายหรือทำลายเนื้อกระดูก และแทบจะไม่เป็นภัยต่อชีวิต มะเร็งกระดูกปฐมภูมิถูกจัดอยู่ในกลุ่มมะเร็งที่เรียกว่า ซาร์โคมา (Sarcomas) ซาร์โคมาของเนื้อเยื่ออ่อน ซาร์โคมาที่เริ่มต้นในกล้ามเนื้อ ไขมัน เนื้อเยื่อเส้นใย หลอดเลือดหรือเนื้อเยื่อค้ำจุนอื่นของร่างกาย มะเร็งที่แพร่กระจายไปยังกระดูกจากส่วนอื่นของร่างกายเรียกว่ามะเร็งกระดูกระยะแพร่กระจาย หรือมะเร็งกระดูกทุติยภูมิและจะถูกเรียกตามอวัยวะหรือเนื้อเยื่อที่มันเริ่มต้น เช่น มะเร็งเต้านมที่ได้แพร่กระจายไปยังกระดูก เป็นต้น แม้ว่ามะเร็งส่วนใหญ่จะแพร่กระจายไปยังกระดูกได้ แต่การแพร่กระจายของกระดูกมีแนวโน้มเป็นพิเศษกับมะเร็งบางชนิด รวมถึงมะเร็งเต้านมและมะเร็งต่อมลูกหมาก เนื้องอกระยะแพร่กระจายในกระดูกอาจทำให้เกิดกระดูกหัก ปวด และระดับแคลเซียมในเลือดสูงผิดปกติได้ (Institute, 2018)

2. ชนิดของมะเร็งกระดูก

ชนิดของมะเร็งกระดูกปฐมภูมิ (Primary Bone Cancer) ถูกจำแนกตามชนิดของเซลล์ในกระดูกที่เป็นต้นกำเนิดของมะเร็ง (Institute, 2018) ได้แก่

1.1 Osteosarcoma

Osteosarcoma เกิดจากเซลล์สร้างกระดูกที่เรียกว่า Osteoblasts ในเนื้อเยื่อ Osteoid เป็นเนื้อกระดูกที่ยังไม่เจริญเต็มที่ มะเร็งชนิดนี้มักพบที่กระดูกแขนบริเวณใกล้หัวไหล่และกระดูกขาบริเวณใกล้หัวเข่าในเด็ก วัยรุ่น และวัยผู้ใหญ่ตอนต้น แต่สามารถเกิดขึ้นได้ในกระดูกทุกส่วน โดยเฉพาะในผู้สูงอายุ มักมีการเจริญเติบโตอย่างรวดเร็วและแพร่กระจายไปยังอวัยวะอื่น โดยเฉพาะปอด ความเสี่ยงสูงสุดพบในเด็กและวัยรุ่นอายุ 10 – 19 ปี เพศชายมีโอกาสเกิดมากกว่าเพศหญิงในเด็กพบมากในคนผิวดำและกลุ่มชาติพันธุ์อื่นมากกว่าคนผิวขาว แต่ในผู้ใหญ่กลับพบมากในคนผิวขาว ผู้ที่เป็นโรค Paget disease หรือเคยได้รับรังสีบริเวณกระดูก มีความเสี่ยงเพิ่มขึ้นในการเกิด Osteosarcoma

1.2 Chondrosarcoma

Chondrosarcoma เริ่มต้นจากเนื้อเยื่อกระดูกอ่อน (Cartilage) ซึ่งเป็นเนื้อเยื่อเกี่ยวพันชนิดหนึ่งที่ปกคลุมปลายกระดูกและบุข้อต่อ มักพบที่กระดูกเชิงกราน ต้นขาส่วนบน และหัวไหล่ โดยทั่วไปเติบโตช้า แต่บางครั้งอาจโตเร็วและแพร่กระจายไปยังส่วนอื่นของร่างกาย มักพบในผู้ใหญ่อายุมากกว่า 40 ปี และความเสี่ยงเพิ่มขึ้นตามอายุ นอกจากนี้ยังมีชนิดหายากที่เรียกว่า Extraskletal Chondrosarcoma ซึ่งไม่ได้เกิดในกระดูก แต่เกิดในเนื้อเยื่ออ่อนบริเวณแขนและขาส่วนบน

1.3 Ewing Sarcoma

Ewing sarcoma มักเกิดในกระดูก แต่บางครั้งอาจเกิดในเนื้อเยื่ออ่อน เช่น กล้ามเนื้อ ไขมัน เนื้อเยื่อเส้นใย หรือหลอดเลือด มักพบที่กระดูกเชิงกราน ขา หรือซี่โครง แต่สามารถเกิดได้ในกระดูกทุกส่วน มะเร็งชนิดนี้มักเติบโตเร็วและแพร่กระจายไปยังอวัยวะอื่น โดยเฉพาะปอด พบ

มากในเด็กและวัยรุ่นน้อยกว่า 19 ปี เพศชายมีโอกาสเกิดมากกว่าเพศหญิง และพบมากในคนผิวขาวมากกว่าคนผิวดำหรือชาวเอเชีย

1.4 Chordoma

Chordoma เป็นเนื้องอกที่พบได้ยากมาก เกิดในกระดูกของกระดูกสันหลัง มักพบในผู้สูงอายุ และเกิดบริเวณฐานกระดูกสันหลัง (sacrum) หรือฐานกะโหลกศีรษะ ผู้ชายมีโอกาสเกิดมากกว่าผู้หญิงประมาณ 2 เท่า หากพบในเด็กหรือวัยรุ่น มักเกิดบริเวณฐานกะโหลกหรือกระดูกสันหลังส่วนค

นอกจากนี้เนื้องอกกระดูกชนิดไม่ร้าย (Benign) หลายชนิดในบางกรณีที่พบได้น้อยอาจกลายเป็นเนื้องอกชนิดร้ายและแพร่กระจายไปยังส่วนอื่นของร่างกายได้ ตัวอย่างเช่น Giant Cell Tumor of Bone หรือเรียกว่า Osteoclastoma และ Osteoblastoma เนื้องอกจาก Giant Cell Tumor of Bone ส่วนใหญ่มักเกิดบริเวณปลายของกระดูกยาวในแขนและขา โดยเฉพาะใกล้ข้อเข่า เนื้องอกชนิดนี้มักพบในวัยหนุ่มสาวและวัยกลางคน และสามารถมีลักษณะลุกลามเฉพาะที่ทำให้เกิดการทำลายกระดูกได้ ในบางกรณีที่พบได้น้อย เนื้องอกชนิดนี้สามารถแพร่กระจาย (metastasize) ไปยังส่วนอื่นของร่างกาย โดยมักแพร่ไปยังปอด Osteoblastoma เป็นเนื้องอกที่ทำให้เนื้อกระดูกแข็งตามปกติถูกแทนที่ด้วยเนื้อเยื่อที่อ่อนแอกว่าซึ่งเรียกว่า Osteoid เนื้องอกชนิดนี้มักพบที่กระดูกสันหลัง มีการเจริญเติบโตช้า และพบได้ในวัยหนุ่มสาวและวัยกลางคน มีรายงานเพียงบางกรณีที่พบว่าเนื้องอกชนิดนี้กลายเป็นมะเร็งได้

3. สาเหตุที่เป็นไปได้ของมะเร็งกระดูก

แม้ว่ามะเร็งกระดูกปฐมภูมิจะไม่มีสาเหตุที่ชัดเจน แต่นักวิจัยได้ระบุปัจจัยหลายประการที่เพิ่มโอกาสในการเกิดเนื้องอกเหล่านี้



460115265

KU lThesis 6514401007 thesis / recv: 20052569 22:51:00 / seq: 158

1.1 การรักษามะเร็งก่อนหน้านี้นี้ด้วยการฉายรังสี เคมีบำบัด หรือการปลูกถ่ายสเต็มเซลล์ Osteosarcoma พบได้บ่อยขึ้นในผู้ที่เคยได้รับการฉายรังสีภายนอกขนาดสูง โดยเฉพาะบริเวณของร่างกายที่ได้รับรังสีหรือได้รับการรักษาด้วยยาต้านมะเร็งบางชนิด โดยเฉพาะกลุ่ม alkylating agents ผู้ที่ได้รับการรักษาตั้งแต่วัยเด็กจะมีความเสี่ยงเป็นพิเศษนอกจากนี้ Osteosarcoma ยังพบในเด็กส่วนน้อย ประมาณ 5% ที่ได้รับการปลูกถ่ายสเต็มเซลล์เม็ดเลือดชนิด Myeloablative Hematopoietic Stem Cell Transplantation

1.2 เงื่อนไขทางพันธุกรรมบางอย่างมะเร็งกระดูกจำนวนเล็กน้อยเกิดจากภาวะทางพันธุกรรม ตัวอย่างเช่น เด็กที่เป็น Hereditary retinoblastoma มะเร็งจอตาที่ถ่ายทอดทางพันธุกรรม ซึ่งพบได้ไม่บ่อยมีความเสี่ยงสูงต่อการเกิด Osteosarcoma โดยเฉพาะหากได้รับการรักษาด้วยรังสี สมาชิกในครอบครัวที่มี Li-Fraumeni Syndrome มีความเสี่ยงเพิ่มขึ้นต่อการเกิด Osteosarcoma และ Chondrosarcoma รวมถึงมะเร็งชนิดอื่น ๆ นอกจากนี้ ผู้ที่มีความผิดปกติทางพันธุกรรมของกระดูกยังมีความเสี่ยงตลอดชีวิตเพิ่มขึ้นในการเกิด Chondrosarcoma เนื้องอกกระดูกมะเร็ง Chordoma ในเด็กมีความเกี่ยวข้องกับ Tuberous sclerosis complex ซึ่งเป็นโรคทางพันธุกรรมที่ทำให้เกิดเนื้องอกชนิดไม่ร้ายในไต สมอง ตา หัวใจ ปอด และผิวหนัง แม้ว่า Ewing Sarcoma จะไม่ได้มีความเกี่ยวข้องอย่างชัดเจนกับกลุ่มอาการมะเร็งทางพันธุกรรมหรือโรคแต่กำเนิดในเด็ก แต่หลักฐานที่เพิ่มขึ้นบ่งชี้ว่าปัจจัยทางพันธุกรรมที่ถ่ายทอดได้มีบทบาทสำคัญต่อความเสี่ยงในการเกิด Ewing Sarcoma

1.3 ภาวะกระดูกชนิดไม่ร้ายบางชนิดที่มีอายุมากกว่า 40 ปีและเป็น Paget disease of bone ภาวะชนิดไม่ร้ายที่มีลักษณะการสร้างเซลล์กระดูกใหม่ผิดปกติมีความเสี่ยงเพิ่มขึ้นต่อการเกิด osteosarcoma



460115265

KU iThesis 6514401007 thesis / recv: 20052569 22:51:00 / seq: 158

4. ตัวแปรเป้าหมายและปัจจัยที่ส่งผลต่อผลลัพธ์การรักษามะเร็งกระดูก

ในการหาตัวแปรเป้าหมายที่ส่งผลต่อประสิทธิภาพการรักษาโรคเนื้องอกกระดูกของผู้ป่วย จะต้องมีชุดข้อมูลที่เกี่ยวข้องกับประสิทธิภาพหลังการรักษาโรคเนื้องอกกระดูก โดยการศึกษาแบ่งออกเป็น 2 ประเภทได้แก่ (Glenn Heller et al., 2023; Wang et al. 2023; Center, 2024; Board, 2020)

4.1 ตัวแปรตาม

4.1.1 Status (NED, AWD, D) สถานะของผู้ป่วย, หายขาด (No evidence of disease: NED), ยังคงเป็นโรครออยู่ (Alive with disease: AWD) และ ตาย (Dead: D) ใช้ในการติดตามสถานะของผู้ป่วยที่เป็นโรคเนื้องอกกระดูก

NED (No Evidence of Disease) หมายถึงไม่มีหลักฐานการเกิดโรค ผู้ป่วยมีอาการปกติและไม่มีการตรวจพบเนื้องอกหลังจากการรักษา

AWD (Alive With Disease) หมายถึงยังมีชีวิตอยู่พร้อมกับการตรวจพบโรคหรือเนื้องอก ซึ่งอาจจะยังมีการรักษาอย่างต่อเนื่องหรือควบคุมอาการเพื่อป้องกันการแพร่กระจาย

D (Dead) หมายถึงผู้ป่วยเสียชีวิต ซึ่งอาจเกิดจากการลุกลามของโรคหรือสาเหตุอื่นที่เกี่ยวข้อง

4.2 ตัวแปรอิสระ

4.2.1 เพศ (Sex) เพศของผู้ป่วยแบ่งออกเป็นเพศหญิงและเพศชาย เพศของผู้ป่วยอาจมีบทบาทสำคัญในการกลับมาเป็นซ้ำของโรคเนื้องอกกระดูก (Bone tumor) หลังการรักษา เนื่องจากหลายปัจจัยที่เกี่ยวข้องกับเพศสามารถส่งผลต่อการเกิดและการกลับมาเป็นซ้ำของเนื้องอกกระดูกได้

4.2.2 อายุ (Age) อายุของผู้ป่วย ณ เวลาที่วินิจฉัย อายุอาจเป็นอีกปัจจัยหนึ่งที่มีผลต่อโอกาสในการกลับมาเป็นซ้ำของเนื้องอกกระดูกมักพบได้บ่อยในแต่ละช่วงอายุ เช่น Osteosarcoma ที่พบในวัยรุ่น ในขณะที่ Chondrosarcoma พบมากกว่าในผู้สูงอายุ

4.2.3 ระดับความรุนแรง (Grade) ระดับความรุนแรงหรือความก้าวร้าวของเนื้องอกเป็นตัวบ่งชี้ระดับความรุนแรงของเซลล์มะเร็งเซลล์มะเร็งมีมากเพียงใด โดยแบ่งเป็น Intermediate เป็นเกรดระดับความรุนแรงปานกลาง และ High เป็นเกรดระดับความรุนแรงสูงหรือชนิดร้ายแรง (malignant)

Intermediate grade ระดับความรุนแรงปานกลางมีการแพร่กระจายปานกลางและมีโอกาสที่จะแพร่กระจายไปยังเนื้อเยื่อใกล้เคียงหรือส่วนอื่นของร่างกายได้

High grad ระดับความรุนแรงสูงมีโอกาสแพร่กระจายสูง เช่น Osteosarcoma และ Ewing sarcoma ทั้ง 2 ระดับนี้มีโอกาสกลับมาเป็นซ้ำได้อีกหลังการรักษา

4.2.4 Histological type ประเภทพยาธิวิทยาของเนื้องอกมะเร็ง เช่น osteosarcoma หรือ Ewing sarcoma โดยอ้างอิงข้อมูลประเภท Histological type ของชุดข้อมูล ตาม WHO Classification of Tumours of Soft Tissue and Bone 2020 จะได้ดังนี้ (Board, 2020)

ตารางที่ 1 การแบ่ง Histological type ของชุดข้อมูล ตาม WHO Classification of Tumours of Soft Tissue and Bone 2020

Histological type	WHO Tumors (Bone/Soft Tissue)	หมายเหตุ
Pleiomorphic leiomyosarcoma	Smooth muscle tumours (Soft Tissue Sarcoma)	มะเร็งเนื้อเรียบเกิดในเนื้อเยื่ออ่อนมี pleomorphism สูงเซลล์หลากหลาย spindle / giant cells และมีความรุนแรงสูง
Synovial sarcoma	Synovial sarcoma (Soft Tissue Sarcoma)	มะเร็งกล้ามเนื้ออ่อนที่เกิดจากเนื้อเยื่อ Synovial อาจเกิดในกระดูกเป็นบางกรณีมีลักษณะ morphology แบบ monophasic หรือ biphasic

Histological type	WHO Tumors (Bone/Soft Tissue)	หมายเหตุ
Leiomyosarcoma	Smooth muscle tumours (Soft Tissue Sarcoma)	มะเร็งกล้ามเนื้อเรียบในเนื้อเยื่ออ่อน คล้าย pleiomorphic leiomyosarcoma แต่มี cellular pleomorphism น้อยกว่า
Myxofibrosarcoma	Fibroblastic / Myofibroblastic tumours (STS)	มี myxoid stroma ลักษณะ infiltrative recurrence สูงรวมถึง subtype myxoid fibrosarcoma
Undifferentiated – pleiomorphic	Undifferentiated pleiomorphic sarcoma (UPS, STS)	เนื้องอกเนื้อเยื่ออ่อนชนิดร้ายแรงที่ไม่จำเพาะชนิด ก่อนหน้านี้เรียกว่า MFH มีลักษณะเซลล์ spindle cell ที่หลากหลาย
Sclerosing epithelioid fibrosarcoma	Fibroblastic tumours (STS)	พบได้ยาก มี sclerosing stroma และเซลล์แบบ epithelioid เดิบโตช้าแต่มีความเสี่ยงสูงต่อการแพร่กระจาย
Pleiomorphic spindle cell undifferentiated	Undifferentiated pleiomorphic sarcoma (UPS, STS)	UPS variant ที่มี morphology เป็น spindle cell เป็นหลัก ร้ายแรงสูง ไม่มีการจำเพาะชนิด
Malignant solitary fibrous tumor	Fibroblastic tumours (STS)	malignant ของ solitary fibrous tumour มีลักษณะ hypercellular, mitotic activity และ necrosis เกิดในเนื้อเยื่ออ่อน
Undifferentiated pleiomorphic liposarcoma	Liposarcoma (STS)	Liposarcoma แบบ dedifferentiated / pleiomorphic ร้ายแรงมีโอกาสแพร่กระจายสูง
Myxoid fibrosarcoma	Fibroblastic tumours (STS)	มี myxoid matrix ชัดเจนความรุนแรงระดับกลาง มีโอกาสกลับมาเกิดซ้ำในบริเวณเดิม
Poorly differentiated synovial sarcoma	Synovial sarcoma (STS)	Subtype ร้ายแรงของ synovial sarcoma ดัชนีการแบ่งเซลล์สูง เกิดในเนื้อเยื่ออ่อน

Histological type	WHO Tumors (Bone/Soft Tissue)	หมายเหตุ
Pleomorphic sarcoma	Undifferentiated pleomorphic sarcoma (UPS, STS)	UPS / MFH แบบทั่วไป มี spindle cell หลากหลาย ร้ายแรง เกิดในเนื้อเยื่ออ่อน

4.2.5 MSKCC type การแบ่งเนื้องอกกระดูกโดย MSKCC ซึ่งเป็นการจำแนกประเภทเนื้องอกที่เฉพาะเจาะจงมากขึ้นการแบ่งเนื้องอกกระดูกโดย Memorial Sloan Kettering Cancer Center (MSKCC) เป็นเนื้องอกมะเร็งชนิดที่พบในเนื้อเยื่ออ่อน ซึ่งสามารถแพร่กระจายไปยังกระดูกได้ดังนี้

Malignant Fibrous Histiocytoma (MFH) เป็นมะเร็งที่เกิดขึ้นในเนื้อเยื่ออ่อนแต่สามารถแพร่กระจายไปยังกระดูกได้ ในบางกรณี MFH อาจเกิดขึ้นเป็นมะเร็งในกระดูกและทำให้เกิดรอยโรคที่ทำลายกระดูกได้ MFH ที่รุนแรงมักทำให้เกิดอาการปวดและภาวะแทรกซ้อนอย่างรุนแรง การรักษาเกี่ยวข้องกับกำจัดการผ่าตัด เคมีบำบัด และบางครั้งอาจรวมถึงการฉายรังสีด้วย มะเร็งชนิดนี้มีส่วนเกี่ยวข้องกับกระดูกในส่วนน้อยของผู้ป่วย โดยส่วนใหญ่มักอยู่ในรูปแบบของการแพร่กระจายจากมะเร็ง

Leiomyosarcoma มักมีจุดเริ่มต้นมาจากเนื้อเยื่อของกล้ามเนื้อเรียบ เช่น ในมดลูกหรือทางเดินอาหาร แต่ในระยะที่รุนแรงกว่านั้น อาจแพร่กระจายไปยังกระดูกได้ Leiomyosarcoma ที่กระดูกหลักพบได้น้อย แต่การแพร่กระจายไปยังกระดูกพบได้บ่อยกว่า เมื่อ Leiomyosarcoma แพร่กระจาย มักจะส่งผลกระทบต่อแขนขาและกระดูกสันหลัง ทำให้เกิดอาการปวดและกระดูกถูกทำลาย การรักษาโดยทั่วไปจะเกี่ยวข้องกับการผ่าตัดตามด้วยเคมีบำบัดและฉายรังสี

Synovial Sarcoma พบได้บ่อยในผู้ใหญ่วัยหนุ่มสาวและมักส่งผลกระทบต่อเนื้อเยื่ออ่อนรอบข้อต่อ แต่สามารถส่งผลกระทบต่อกระดูกได้โดยการยึดเกาะโดยตรงหรือแพร่กระจาย มะเร็งมักปรากฏเป็นก้อนในบริเวณต่างๆ เช่น ต้นขา เข่า หรือแขนขาส่วนบน และอาจทำให้กระดูกถูกทำลายในระยะลุกลาม การแพร่กระจายของกระดูกเป็นปัจจัยสำคัญที่ทำให้การรักษามีความซับซ้อน มักแนะนำให้ทำการผ่าตัดตามด้วยเคมีบำบัดและบางครั้งอาจฉายรังสี ขึ้นอยู่กับขอบเขตของการแพร่กระจายของโรค

4.2.6 Site of primary STS ตำแหน่งของเนื้องอกในกระดูกพัฒนาขึ้นในร่างกายในระยะเริ่มแรก บริเวณต่างๆ ของร่างกายที่เนื้องอกนี้สามารถเกิดขึ้นได้

ต้นขาซ้าย (Left Thigh) ตำแหน่งเนื้องอกสามารถเกิดขึ้นในกล้ามเนื้อหรือเนื้อเยื่อไขมันที่ต้นขา

ต้นขาขวา (Right Thigh) เช่นเดียวกับต้นขาซ้าย ต้นขาขวาก็เป็นจุดที่มักเกิดเนื้องอกในเนื้อเยื่ออ่อนต่างๆ ได้

ก้นขวา (Right Buttock) ก้นขวามีเนื้อเยื่อหลายชนิด เช่น กล้ามเนื้อและไขมัน

ก้นซ้าย (Left Buttock) เช่นเดียวกับก้นขวา ก้นซ้ายก็อาจเป็นจุดที่พบเนื้องอก

รอบๆ สะบัก (Parascapular) บริเวณรอบๆ กระดูกสะบัก (scapula) เป็นตำแหน่งที่เนื้องอกอาจเกิดขึ้น

รอบๆ สะบักขวา (Right Parascapular) เช่นเดียวกับด้านซ้าย บริเวณรอบๆ กระดูกสะบัก ขวาก็สามารถเกิดเนื้องอกได้

กล้ามเนื้อแขนซ้าย (Left Biceps) แม้ว่าจะไม่พบบ่อย แต่เนื้องอกในกล้ามเนื้อแขนซ้ายก็สามารถเกิดได้

4.2.7 วิธีการรักษา (Treatment) วิธีการรักษาที่ผู้ป่วยได้รับแบ่งออกเป็น การผ่าตัด (Surgery), การฉายรังสี (Radiotherapy) และ เคมีบำบัด (Chemotherapy)

การรักษาด้วยรังสี (Radiotherapy) มีบทบาทสำคัญในการรักษาผู้ป่วยที่มีการแพร่กระจายของมะเร็งไปยังกระดูก โดยมีวัตถุประสงค์หลักเพื่อบรรเทาอาการปวด ลดการลุกลามของก้อนเนื้องอก และช่วยควบคุมโรคเฉพาะที่ โดยเฉพาะในผู้ป่วยที่ไม่เหมาะสมต่อการผ่าตัดหรือมีภาวะเสี่ยงสูงจากการผ่าตัด การฉายรังสีสามารถช่วยลดอาการปวดจากกระดูกที่มีรอยโรคได้อย่างมีประสิทธิภาพ และช่วยเพิ่มคุณภาพชีวิตของผู้ป่วยในระยะประคับประคอง นอกจากนี้การฉายรังสี

ยังสามารถใช้ร่วมกับการผ่าตัดได้ทั้งในรูปแบบการฉายรังสีก่อนการผ่าตัดหรือหลังการผ่าตัด เพื่อช่วยควบคุมเซลล์มะเร็งที่อาจหลงเหลืออยู่ในบริเวณผ่าตัด และลดความเสี่ยงของการกลับเป็นซ้ำเฉพาะที่ โดยเฉพาะในกรณีของเนื้องอกกระดูกที่มีการลุกลามต่อเนื่องข้างเคียงหรือมีขอบเขตของการตัดที่ไม่ชัดเจน

การผ่าตัด (Surgery) รักษาการแพร่กระจายไปยังกระดูกมีเป้าหมายหลัก 2 ประการ ได้แก่ การรักษาแบบประคับประคองเพื่อบรรเทาอาการปวด ความไม่มั่นคง และอัมพาต และการผ่าตัดตัดก้อนเนื้องอกออกเพื่อการรักษาโรคให้หายขาด การผ่าตัดตัดก้อนเนื้องอกออกทั้งหมดตามหลักเนื้องอกวิทยา (oncologically en bloc resection) ร่วมกับการสร้างกระดูกทดแทนบริเวณที่เกิดความบกพร่องของกระดูก เป็นวิธีการรักษาที่เหมาะสมที่สุดในกรณีที่มีการแพร่กระจายไปยังกระดูกเพียงตำแหน่งเดียว การแพร่กระจายไปยังกระดูกสามารถเกิดขึ้นได้ที่กระดูกแขนขา กระดูกเชิงกราน หรือกระดูกสันหลัง โดยวิธีการตัดก้อนเนื้องอกและการสร้างกระดูกทดแทนจะแตกต่างกันไปตามลักษณะทางกายวิภาคของแต่ละบริเวณ ตัวอย่างเช่น ในกระดูกเชิงกราน โดยเฉพาะบริเวณเบ้าสะโพก มีทางเลือกหลายวิธีในการสร้างกระดูกทดแทน ได้แก่ การสร้างใหม่ให้สอดคล้องกับโครงสร้างทางกายวิภาคโดยใช้อุปกรณ์ที่ออกแบบเฉพาะราย หรือการใช้กระดูกของผู้ป่วยเองที่ผ่านกระบวนการนำกลับมาใช้ใหม่ ในกรณีที่คาดว่าจะมีพยากรณ์โรคระยะยาวที่ดี ในช่วงหลัง แม้ว่าการผ่าตัดจะมีข้อจำกัดในระยะแรกด้านความรุนแรงของการผ่าตัด เช่น การเสียเลือดจำนวนมากก็ตาม โดยหลักการแล้ว การผ่าตัดแบบประคับประคองมีเป้าหมายเพื่อคงความมั่นคงของโครงสร้างกระดูกในระยะยาว โดยใช้การผ่าตัดที่มีความรุนแรงน้อยที่สุด การใช้แท่งโลหะในโพรงกระดูกและการยึดตรึงด้วยแผ่นโลหะเป็นวิธีที่ใช้บ่อยในกระดูกแขนขา แต่มีอัตราการล้มเหลวหลังผ่าตัดค่อนข้างสูง ดังนั้น ศัลยแพทย์ควรพิจารณาใช้แท่งโลหะในโพรงกระดูกชนิดยาว และก้านโลหะชนิดยาวสำหรับการสร้างกระดูกทดแทนด้วยข้อเทียม ร่วมกับการใช้ซีเมนต์ยึดกระดูก เพื่อลดอัตราการล้มเหลว (Hayashi and Tsuchiya, 2022)


การรักษาด้วยยาเคมีบำบัด (Chemotherapy) เป็นแนวทางการรักษาเชิงระบบ (systemic therapy) ที่มีบทบาทในการควบคุมโรคในผู้ป่วยที่มีการแพร่กระจายของมะเร็งไปยังกระดูก หรือมีความเสี่ยงต่อการแพร่กระจายไปยังอวัยวะอื่น โดยมีวัตถุประสงค์เพื่อทำลายเซลล์มะเร็งที่กระจายอยู่ทั่วร่างกาย ซึ่งไม่สามารถกำจัดได้ด้วยการรักษาเฉพาะที่ เช่น การผ่าตัดหรือการฉายรังสีเพียงอย่างเดียวในผู้ป่วยมะเร็งกระดูกชนิดร้ายแรงบางชนิด การให้เคมีบำบัดมักใช้ร่วมกับการผ่าตัดในลักษณะของการให้ยาก่อนผ่าตัด (neoadjuvant chemotherapy) เพื่อลดขนาด

ก้อนเนื้องอก และเพิ่มโอกาสในการผ่าตัดตัดก้อนเนื้องอกออกได้อย่างเหมาะสมตามหลักเนื้องอกวิทยา รวมถึงการให้ยาหลังผ่าตัด (adjuvant chemotherapy) เพื่อกำจัดเซลล์มะเร็งที่อาจหลงเหลืออยู่ และลดความเสี่ยงของการกลับเป็นซ้ำของโรค

5. วิธีการแก้ปัญหาข้อมูลไม่สมดุล

การรวบรวมชุดข้อมูล (Dataset) ที่แต่ละคลาสมีจำนวนข้อมูลเท่ากันมีความเป็นไปได้ยาก ในความเป็นจริง ข้อมูลมักจะไม่สมดุล (Imbalanced) อย่างสมบูรณ์ และเมื่อสร้างตัวแบบสำหรับการจำแนกประเภท (Classification) สิ่งนี้อาจก่อให้เกิดปัญหาได้ เพื่อช่วยแก้ปัญหานี้ จึงได้มีการใช้เทคนิค Undersampling (Baladram, 2024) วิธีการแก้ปัญหาสุ่มตัวอย่างน้อยเกินไป (Undersampling Methods) การสุ่มตัวอย่างน้อยเกินไปจะลดขนาดกลุ่มที่ใหญ่กว่าเพื่อให้มีขนาดใกล้เคียงกับกลุ่มที่เล็กกว่ามากขึ้นมีวิธีการดังต่อไปนี้


5.1 Random Undersampling จะสุ่มลบตัวอย่างออกจากกลุ่มที่ใหญ่กว่าจนกว่าจะมีขนาดเท่ากับกลุ่มที่เล็กกว่า เช่นเดียวกับการสุ่มตัวอย่างมากเกินไปวิธีการนี้ค่อนข้างง่าย แต่อาจกำจัดข้อมูลสำคัญที่แสดงให้เห็นว่ากลุ่มแตกต่างกันอย่างไร การสุ่มตัวอย่างน้อยเกินไปจะลบจุดที่เลือกแบบสุ่มออกจากกลุ่มที่ใหญ่กว่า (B และ C) ในขณะที่ยังคงจะแนบทั้งหมดจากกลุ่มที่เล็กกว่า (A) ไม่เปลี่ยนแปลง



ภาพที่ 2 Random Undersampling

ที่มา: Baladram (2024)

5.2 Tomek Links เป็นวิธีการสุ่มตัวอย่างน้อยเกินไปที่ทำให้เส้นระหว่างกลุ่มชัดเจนขึ้น ค้นหาของตัวอย่างจากกลุ่มต่างๆ ที่เหมือนกันจริงๆ เมื่อพบคู่ที่ตัวอย่างเป็นเพื่อนบ้านที่ใกล้ชิดที่สุดของกันและกัน แต่อยู่ในกลุ่มที่แตกต่างกัน มันจะกำจัดตัวอย่างออกจากกลุ่มที่ใหญ่กว่า Tomek Links ระบุคู่ของจุดจากกลุ่มต่างๆ (AB, BC) ที่เป็นเพื่อนบ้านที่ใกล้ชิดที่สุดจุดจากกลุ่มที่ใหญ่กว่า (B และ C) ที่ก่อตัวเป็นคู่เหล่านี้จะถูกลบออกในขณะที่จุดทั้งหมดจากกลุ่มที่เล็กกว่า (A) จะถูกเก็บไว้



ภาพที่ 3 Tomek Links


ที่มา: Baladram (2024)


5.3 Near Miss เป็นชุดของเทคนิคการสุ่มตัวอย่างน้อยเกินไปที่ทำงานบนกฎที่ต่างกัน แนวคิดหลักในที่นี้คือการเก็บตัวอย่างที่ให้ข้อมูลมากที่สุดจากกลุ่มที่ใหญ่กว่าและกำจัดตัวอย่างที่ไม่สำคัญเท่า NearMiss-1 เก็บคะแนนจากกลุ่มที่ใหญ่กว่า (B และ C) ที่อยู่ใกล้กับกลุ่มที่เล็กกว่า (A) มากที่สุด ในขณะที่ลบส่วนที่เหลือออก ที่นี้จะเก็บเฉพาะจุด B และ C ที่ใกล้กับจุด A มากที่สุดเท่านั้น เช่น

Near Miss-1 เก็บตัวอย่างจากกลุ่มที่ใหญ่กว่าซึ่งใกล้เคียงกับตัวอย่างในกลุ่มเล็กที่สุด

Near Miss-2 เก็บตัวอย่างจากกลุ่มใหญ่ที่มีระยะทางเฉลี่ยน้อยที่สุดกับเพื่อนบ้านที่ใกล้ที่สุดสามคนในกลุ่มที่เล็กกว่า


Near Miss-3 เก็บตัวอย่างจากกลุ่มใหญ่ที่อยู่ห่างจากตัวอย่างอื่นๆ ในกลุ่มของตนเองมากที่สุด





ภาพที่ 4 NearMiss
ที่มา: Baladram (2024)

5.4 Edited Nearest Neighbors (ENN) จะกำจัดตัวอย่างที่อาจเป็นสัญญาณรบกวนหรือค่าผิดปกติ สำหรับแต่ละตัวอย่างในกลุ่มที่ใหญ่กว่า จะตรวจสอบว่าเพื่อนบ้านที่ใกล้ที่สุดส่วนใหญ่อยู่ในกลุ่มเดียวกันหรือไม่ หากไม่เป็นเช่นนั้น จะลบตัวอย่างนั้นออก สิ่งนี้ช่วยสร้างขอบเขตที่ชัดเจนยิ่งขึ้นระหว่างกลุ่ม ENN ลบจุดออกจากกลุ่มที่ใหญ่กว่า (B และ C) ซึ่งเพื่อนบ้านที่ใกล้ที่สุดส่วนใหญ่อยู่ในกลุ่มอื่น ในพล็อตด้านขวา จุดที่ขีดฆ่าจะถูกลบออกเนื่องจากเพื่อนบ้านที่ใกล้ที่สุดส่วนใหญ่มาจากกลุ่มอื่น



ภาพที่ 5 Edited Nearest Neighbors (ENN)


ที่มา: Baladram (2024)

6. ตัวแบบสำหรับการทำนาย

6.1 Random Forest

ตัวแบบ Random Forest ใช้การตัดสินใจหลายต้นไม้ตัดสินใจ (Decision Trees) โดยการสุ่มข้อมูลและคุณลักษณะ (Features) ที่จะใช้ในการสร้างแต่ละต้นไม้ สำหรับการสร้างแต่ละต้นไม้จะทำการ สุ่มตัวอย่างข้อมูล (Sampling) โดยการใช้เทคนิคที่เรียกว่า การบูตสแตรป (Bootstrapping) ซึ่งเป็นการสุ่มเลือกข้อมูลบางส่วนจากชุดข้อมูลที่มี โดยอาจมีการเลือกข้อมูลซ้ำกันในการสร้างแต่ละ node การตัดสินใจของต้นไม้ จะเลือกคุณลักษณะบางตัวจากทั้งหมดแต่ไม่ใช้ทั้งหมด เพื่อเพิ่มความหลากหลายในการสร้างต้นไม้และลดการพึ่งพาคุณลักษณะบางตัว (Logunova, 2022) นอกจากกระบวนการสุ่มข้อมูลและสุ่มคุณลักษณะในการสร้างต้นไม้แต่ละต้นแล้ว ตัวแบบ Random Forest ยังใช้หลักการของการรวมผลการทำนายจากต้นไม้ตัดสินใจหลายต้น (Ensemble Learning) โดยในกรณีของปัญหาการจำแนกประเภท จะใช้วิธีการลงคะแนนเสียงข้างมาก (Majority Voting) จากต้นไม้ทั้งหมด ส่วนในกรณีของปัญหาการถดถอย จะใช้ค่าเฉลี่ยของผลลัพธ์จากต้นไม้ทุกต้นเป็นผลการทำนายสุดท้าย แนวคิดดังกล่าวช่วยลดปัญหาการเกิด Overfitting ซึ่งมักพบในตัวแบบ Decision Tree เพียงต้นเดียว และช่วยเพิ่มเสถียรภาพของแบบจำลองในการทำนายข้อมูลใหม่

แนวคิดพื้นฐานของ Random Forest ถูกพัฒนาขึ้นบนหลักการของการสุ่มทั้งในระดับข้อมูลและคุณลักษณะ เพื่อสร้างความแตกต่างระหว่างต้นไม้แต่ละต้นให้มากที่สุด แล้วจึงนำผลลัพธ์ของต้นไม้ทั้งหมดมารวมกัน ซึ่งทำให้ตัวแบบสามารถลดความแปรปรวน (Variance) ของโมเดลลงได้อย่างมีประสิทธิภาพ โดยไม่เพิ่มอคติ (Bias) มากนัก



ภาพที่ 6 Random Forest

ที่มา: Susmit (2024)

จุดเด่นของ Random Forest

1. สามารถทำงานได้ดีกับข้อมูลที่มีหลายปัจจัยร่วมกัน
2. มีความเสถียรในการทำนาย เพราะใช้หลายต้นไม้มาช่วยตัดสินใจร่วมกัน
3. สามารถใช้กับปัญหา Multi-class Classification ได้ดี เช่น NED, AWD และ D
4. ข้อมูลที่กระจายไม่สม่ำเสมอ Random Forest มักได้รับผลกระทบน้อย

ข้อจำกัดของ Random Forest

1. ตัวแบบอาจทำนายคลาสใหญ่ได้ดีกว่าคลาสเล็กทำให้ Recall ของ class D ต่ำได้
2. ไม่สามารถอธิบายความสัมพันธ์เชิงสาเหตุหรือค่า coefficient ได้ตรง ๆ

3. มักให้ความสำคัญกับตัวแปรที่มีจำนวน category มากหรือมีการแบ่งข้อมูลได้หลายแบบ

4. ตัวแบบต้องสร้างต้นไม้จำนวนมากทำให้ใช้เวลา Train มากใช้ทรัพยากรเครื่องสูงแม้ในชุดข้อมูลจะยังไม่เป็นปัญหารุนแรงก็ตาม

6.2 Logistic Regression

การถดถอยโลจิสติกตามจำนวนกลุ่มของตัวแปรตามจะแบ่งได้ 2 ประเภท นั่นคือ เมื่อตัวแปรตามมีเพียง 2 ค่าหรือกลุ่มข้อมูลแบ่งออกได้เป็น 2 กลุ่มย่อย กรณีนี้จะเรียกว่า การวิเคราะห์การถดถอยโลจิสติกแบบทวิ (Binary Logistic Regression) ใช่หรือไม่ใช่ ในทางกรเรียนรู้ของเรื่องจักรการถดถอยโลจิสติกแบบทวินั้นจะแบ่งเป็น 0 และ 1 (GeeksforGeeks, 2024) และเมื่อตัวแปรตามมีค่ามากกว่า 2 ค่า หรือ หน่วยข้อมูลสามารถแบ่งออกเป็นกลุ่มย่อยได้มากกว่า 2 กลุ่ม กรณีนี้จะเรียกว่า การวิเคราะห์การถดถอยโลจิสติกคอนเนกนาม (Multinomial Logistic Regression Analysis) เช่น การศึกษาปัจจัยที่ส่งผลต่อประสิทธิภาพการรักษาโรคเนื้องอกกระดูกของผู้ป่วย มีตัวแปรตามคือผลการรักษาของผู้ป่วย (NED, AWD, D) และ ตัวแปรอิสระ ได้แก่ เพศ, อายุ, ระดับความรุนแรงของเนื้องอก, ประเภทเนื้องอกกระดูกทางพยาธิสภาพ, การแบ่งเนื้องอกกระดูกโดย MSKCC, ตำแหน่งของเนื้องอกกระดูก และวิธีการรักษา (GeeksforGeeks, 2024)

ในกรณีตัวแปรตาม (y) มี 2 ค่า จะเรียกว่า ตัวแบบการถดถอยโลจิสติกทวิภาค (Binary Logistic Model) ซึ่งมีตัวแบบดังนี้

$$\log\left(\frac{p_y}{Q_y}\right) = \log\left(\frac{p_y}{1-p_y}\right) = b_0 + b_1x_1 + \dots + b_px_p$$

เมื่อ P_y คือ ความน่าจะเป็นของการเกิดเหตุการณ์ที่สนใจ ($y=1$)
 Q_y คือ ความน่าจะเป็นของการไม่เกิดเหตุการณ์ที่สนใจ ($y=0$)
 b_i คือ ตัวประมาณของ β_i ด้วยวิธีภาวะน่าจะเป็นสูงสุด โดยที่ $i=0, 1$

ดังนั้น $Q_y = 1 - P_y$

จากความสัมพันธ์ระหว่างตัวแปรตามและตัวแปรอิสระของการวิเคราะห์การถดถอย โลจิสติกไม่อยู่ในรูปแบบเชิงเส้น ทำให้ต้องมีการปรับให้อยู่ในรูปแบบของอัตราส่วน (Odds) หรือ อัตราส่วนอัตราส่วน (Odd Ratio) นั่นคือเป็นการปรับให้ความสัมพันธ์ระหว่างตัวแปรตามและตัวแปรอิสระอยู่ในรูปแบบเชิงเส้น ซึ่งอัตราส่วนหรืออัตราส่วนอัตราส่วนนั้นหมายถึงอัตราส่วนระหว่างโอกาสที่เหตุการณ์จะเกิดเหตุการณ์ที่สนใจ $P(Y=1)$ กับโอกาสที่เหตุการณ์จะไม่เกิดเหตุการณ์ที่สนใจ $P(Y=0)$ เขียนได้ดังนี้

$$\text{Odds} = \frac{P_y}{Q_y}$$

ดังนั้นอัตราส่วนอัตราส่วนจึงเป็นค่าที่แสดงถึงโอกาสที่จะเกิดเหตุการณ์ที่สนใจว่าเป็นกี่เท่าของโอกาสที่จะไม่เกิดเหตุการณ์ที่สนใจ ซึ่งถ้าอัตราส่วนอัตราส่วนมีค่ามากกว่า 1 แสดงว่าโอกาสที่จะเกิดเหตุการณ์ที่สนใจมีมากกว่าโอกาสที่จะไม่เกิดเหตุการณ์ที่สนใจ ถ้าอัตราส่วนอัตราส่วนมีค่าเท่ากับ 1 แสดงว่าโอกาสที่จะเกิดเหตุการณ์ที่สนใจและไม่เกิดเหตุการณ์ที่สนใจมีเท่ากัน และถ้าอัตราส่วนอัตราส่วนมีค่าน้อยกว่า 1 แสดงว่าโอกาสที่จะเกิดเหตุการณ์ที่สนใจต่ำกว่าโอกาสที่จะไม่เกิดเหตุการณ์ที่สนใจ (กัลยา, 2554)

แต่ในกรณีตัวแปรตามมีค่ามากกว่า 2 ค่า เช่น $k > 2$ ยุทธ (2555) ได้กล่าวไว้ว่าจะได้ลอจิทจำนวนเท่ากับ $(k-1)$ และจะนำลอจิทแต่ละค่ามาเปรียบเทียบกับกลุ่มฐาน (Baseline Category) ซึ่งค่าสัมประสิทธิ์ทั้งหลายของตัวแปรที่เป็นกลุ่มฐานจะเท่ากับ 0 เพื่อเป็นฐานในการเปรียบเทียบให้กับค่าของกลุ่มอื่น หากกรณีที่มีตัวแปรตามจำนวน 3 หรือ 4 ตัว โดยที่กลุ่มที่เป็นฐานคือ k และเมื่อเปรียบเทียบกับกลุ่มที่ i จะได้ตัวแบบลอจิทดังนี้

$$\log \left(\frac{P(\text{กลุ่ม } i)}{P(\text{กลุ่ม } k)} \right) = b_{i0} + b_{i1}x_1 + \dots + b_{ip}x_p$$

สัมประสิทธิ์ $b_{i0}, b_{i1}, b_{i2}, \dots, b_{ip}$ ของกลุ่มที่ i และกลุ่มที่เป็นฐานจะมีค่าเป็น $b_{k0} = b_{k1} = \dots = b_{kp} = 0$ และการวิเคราะห์จะได้ผลตามนี้ คือ ถ้าตัวแปรตาม (y) มี 3 ค่า หรือ $k = 3$ จะได้สัมประสิทธิ์ 2 ชุด มาจาก $k - 1$ แต่กลุ่มที่เป็นฐานจะมี 3 ค่าตามตัวแปรตามใน 2 ชุดนั้น ซึ่งในชุด

ที่ 1 แสดงค่าสัมประสิทธิ์ของ $y = 1$ เปรียบเทียบกับ $y = 3$ และชุดที่ 2 จะแสดงค่าสัมประสิทธิ์ของ $y = 2$ เปรียบเทียบกับ $y = 3$

ตัวอย่างการเปรียบเทียบกลุ่มของผู้วิจัยที่สนใจศึกษานักเรียนมัธยมศึกษาปีที่ 3 จะเลือกเข้ามัธยมศึกษาปีที่ 4 โรงเรียนใดใน 3 โรงเรียน ได้แก่ Aschool Bschooll และ Cschooll ในการเลือกนี้ผู้วิจัยสงสัยเพศของนักเรียนจะมีผลต่อการเลือกโรงเรียนหรือไม่ โดยให้เพศหญิงเป็นกลุ่มที่เป็นฐาน ค่าสัมประสิทธิ์ของเพศหญิงจะเท่ากับ 0 ผู้วิจัยจะได้ตัวแบบลอจิสต์ 2 ค่าที่ไม่ซ้ำซ้อนกัน ดังนี้

$$g_1 = \left(\frac{P(\text{Aschooll})}{P(\text{Cschooll})} \right) = b_{10} + b_{11}(\text{ชาย})$$

$$g_2 = \left(\frac{P(\text{Bschooll})}{P(\text{Cschooll})} \right) = b_{20} + b_{21}(\text{ชาย})$$

เลขที่กำกับของตัวแปร

เลขที่กำกับของ logit

จุดเด่นของ Logistic Regression

1. เหมาะกับชุดข้อมูลขนาดเล็กถึงปานกลาง
2. สามารถดูความสัมพันธ์ของแต่ละปัจจัยต่อผลลัพธ์ได้ชัดเจนผ่าน coefficient
3. เมื่อข้อมูลมีขนาดไม่มากจะให้ผลลัพธ์ที่คงที่และไม่แกว่งมาก
4. ใช้เวลาในการฝึกตัวแบบน้อยและใช้ทรัพยากรเครื่องต่ำ

ข้อจำกัดของ Logistic Regression

1. ถ้าข้อมูลมีความซับซ้อน Logistic Regression อาจทำนายได้ไม่ดีเท่าตัวแบบอื่น

2. หากจำนวนข้อมูลในแต่ละคลาสไม่สมดุลเช่น คลาส D มีจำนวนข้อมูลน้อยกว่า NED ตัวแบบอาจเรียนรู้คลาสที่มีข้อมูลมากได้ดีกว่า ทำให้ Recall ของคลาสเล็กต่ำ

3. หากตัวแปรบางตัวมีความสัมพันธ์กันสูงอาจส่งผลกระทบต่อความเสถียรของค่า Coefficient และทำให้การตีความผลลัพธ์คลาดเคลื่อน

4. ตัวแบบพึ่งพาคุณภาพของ Feature ค่อนข้างมากหาก Feature ไม่สามารถอธิบายผลลัพธ์ได้ดีประสิทธิภาพของตัวแบบจะลดลงอย่างชัดเจน

6.3 Support Vector Machine (SVM)

เป็นเทคนิคการเรียนรู้ของเครื่องแบบจำแนกประเภท (Classification) ที่ใช้หลักการค้นหาเส้นขอบเขตการแบ่งกลุ่ม (Hyperplane) ที่ดีที่สุดในการแยกกลุ่มข้อมูลให้ออกจากกันได้ชัดเจนที่สุด โดยพยายามทำให้ระยะห่างระหว่างเส้นขอบเขตกับจุดข้อมูลที่ใกล้ที่สุด มีค่ามากที่สุด เพื่อเพิ่มความสามารถในการจำแนกข้อมูลใหม่ (Géron, 2019)

ในกรณีที่ข้อมูลสามารถแยกออกจากกันได้อย่างสมบูรณ์ (Linearly Separable) SVM จะค้นหา Hyperplane ที่ทำให้ระยะ Margin มีค่ามากที่สุดภายใต้เงื่อนไขที่ข้อมูลทุกจุดถูกจัดกลุ่มได้ถูกต้อง อย่างไรก็ตาม ในสถานการณ์จริงข้อมูลมักไม่สามารถแยกออกจากกันได้อย่างสมบูรณ์ ดังนั้นจึงมีการใช้แนวคิดของ Soft Margin โดยอนุญาตให้มีบางจุดข้อมูลถูกจัดกลุ่มผิดพลาดได้ เพื่อให้โมเดลมีความยืดหยุ่นมากขึ้น พารามิเตอร์ที่สำคัญของ SVM คือค่าคงที่ C ซึ่งทำหน้าที่ควบคุมสมดุลระหว่างการเพิ่มระยะ Margin ให้กว้างที่สุด กับการลดจำนวนตัวอย่างที่ถูกจัดกลุ่มผิดพลาด หากกำหนดค่า C สูง โมเดลจะให้ความสำคัญกับการจำแนกข้อมูลฝึกให้ถูกต้องมากขึ้น แต่อาจเกิดปัญหา Overfitting ในทางกลับกัน หากกำหนดค่า C ต่ำ โมเดลจะยอมให้มีความคลาดเคลื่อนของการจำแนกได้มากขึ้น เพื่อให้ได้เส้นขอบเขตที่เรียบและมีความสามารถในการอธิบายข้อมูลใหม่ได้ดีกว่า

สำหรับข้อมูลที่ไม่สามารถแยกออกจากกันได้ด้วยเส้นตรง SVM สามารถขยายขีดความสามารถด้วยเทคนิคที่เรียกว่า Kernel Trick ซึ่งเป็นการแปลงข้อมูลจากปริภูมิต้นฉบับไปยังปริภูมิที่มีมิติสูงขึ้น เพื่อให้สามารถสร้างเส้นขอบเขตที่ไม่เป็นเชิงเส้นได้ในปริภูมิต้นฉบับ โดยไม่



จำเป็นต้องคำนวณการแปลงมิติอย่างชัดเจน ตัวอย่างของ kernel ที่นิยมใช้ ได้แก่ Linear Kernel, Polynomial Kernel และ Radial Basis Function (RBF) Kernel

ในงานจำแนกประเภทหลายกลุ่ม (Multi-class Classification) ซึ่งมากกว่าสองกลุ่ม เช่น กรณีสถานะผู้ป่วย NED, AWD และ D สามารถประยุกต์ใช้ SVM ได้โดยอาศัยกลยุทธ์การแบ่งปัญหาออกเป็นหลายปัญหาย่อย เช่น One-versus-rest หรือ One-versus-one แล้วนำผลลัพธ์จากตัวจำแนกหลายตัวมาสรุปเป็นผลการทำนายสุดท้าย

จุดเด่นของ Support Vector Machine

1. เหมาะกับชุดข้อมูลขนาดเล็กถึงปานกลางเพราะตัวแบบสามารถสร้าง decision boundary ได้ดีแม้ข้อมูลไม่มาก
2. มีประสิทธิภาพดีในงาน Classification โดยเฉพาะเมื่อข้อมูลแต่ละคลาสมีความแตกต่างกัน
3. มีการควบคุมความซับซ้อนของตัวแบบผ่าน Parameter เช่น C ทำให้ตัวแบบสามารถ Generalize กับข้อมูลใหม่ได้ดีเมื่อข้อมูลมีขนาดไม่มากจะให้ผลลัพธ์ที่คงที่และไม่แกว่งมาก
4. สามารถใช้ข้อมูลหลาย Feature ร่วมกันเพื่อช่วยแยกแต่ละกลุ่มได้ดี

ข้อจำกัดของ Support Vector Machine


1. ถ้าข้อมูลมีความซับซ้อน Logistic Regression อาจทำนายได้ไม่ดีเท่าตัวแบบอื่น
2. หากคลาส D มีข้อมูลน้อยกว่าคลาสอื่นตัวแบบอาจเรียนรู้คลาสใหญ่ได้ดีกว่าส่งผลให้ Recall ของคลาส D ต่ำ
3. พารามิเตอร์ เช่น C , Kernel และ Gamma ส่งผลต่อผลลัพธ์ของโมเดลอย่างมากหากเลือกไม่เหมาะสมประสิทธิภาพอาจลดลง

4. ตัวแบบไวต่อขนาดของข้อมูลแต่ละ Feature

6.4 Artificial Neural Network (ANN)

เป็นแบบจำลองการเรียนรู้ของเครื่องที่เลียนแบบการทำงานของสมองมนุษย์ โดยประกอบด้วยโหนด (nodes) ที่ทำหน้าที่คล้ายเซลล์ประสาท (neurons) ซึ่งถูกเชื่อมโยงกันผ่านชั้นต่าง ๆ ได้แก่ ชั้นข้อมูลเข้า (Input layer), ชั้นซ่อน (Hidden layers) และชั้นผลลัพธ์ (Output layer) แต่ละโหนดจะประมวลผลข้อมูลผ่านฟังก์ชันถ่ายโอน (activation function) และถ่ายทอดผลลัพธ์ไปยังชั้นถัดไป โครงข่ายประสาทเทียมสามารถเรียนรู้ความสัมพันธ์ที่ซับซ้อนระหว่างตัวแปรได้ดี เหมาะกับข้อมูลขนาดใหญ่หรือไม่เป็นเชิงเส้น (non-linear) (Walczak, 2023)

ในการทำงานกระบวนการที่เกิดขึ้นใน ANN จะเริ่มจากการส่งข้อมูลผ่าน Input Layer โดยในแต่ละนิวรอนของชั้นนี้จะรับข้อมูลและทำการคูณด้วย น้ำหนัก (Weights) ที่กำหนดไว้ และเพิ่มค่า Bias ก่อนที่จะส่งต่อไปยัง Hidden layer ใน Hidden layer ข้อมูลที่ผ่านการคำนวณจะถูกส่งผ่าน ฟังก์ชันการกระตุ้น (Activation function) เช่น ReLU (Rectified Linear Unit) หรือ Sigmoid เพื่อให้ตัวแบบสามารถเรียนรู้และจำลองลักษณะเชิงซ้อนของข้อมูลได้ เมื่อข้อมูลผ่านการประมวลผลใน Hidden Layer ทั้งหมดแล้ว จะถูกส่งไปที่ Output layer ซึ่งจะให้ผลลัพธ์สุดท้ายของตัวแบบ เช่น ผลการจำแนกประเภท (Class label) หรือค่าทำนาย (Steven Walczak and Narciso Cerpa) (Simplilearn, 2024)



ภาพที่ 7 Artificial neural network (ANN)

ที่มา: Sayad (2010)

จุดเด่นของ Artificial Neural Network

1. สามารถเรียนรู้ความสัมพันธ์ของหลาย Feature พร้อมกันได้ดี
2. สามารถใช้กับปัญหา Multi-class Classification และมักให้ผลลัพธ์ที่ดีเมื่อข้อมูลมีรูปแบบซับซ้อน
3. สามารถเรียนรู้รูปแบบจากข้อมูลหลายประเภทพร้อมกันทั้งข้อมูลตัวเลขและ Categorical
4. สามารถเพิ่มประสิทธิภาพได้ด้วยการปรับ Architecture

ข้อจำกัดของ Artificial Neural Network

1. มีการปรับพารามิเตอร์หลายส่วน เช่น จำนวน Hidden Layers, Neurons และ Learning Rate หากกำหนดไม่เหมาะสมอาจส่งผลต่อประสิทธิภาพของตัวแบบ
2. เป็นตัวแบบลักษณะ Black-Box ทำให้การอธิบายว่าปัจจัยใดส่งผลต่อผลลัพธ์ทำได้ยาก
3. ต้อง Preprocessing ข้อมูลค่อนข้างมาก เพื่อให้ตัวแบบเรียนรู้ได้ดี
4. มีโอกาสเกิด Overfitting ได้ง่ายหากข้อมูลไม่มากตัวแบบอาจจำข้อมูลใน Training set มากเกินไป ทำให้ผลลัพธ์บน Test set ลดลง

6.5 K-Nearest Neighbors (KNN)

เป็นอัลกอริทึมสำหรับการจำแนกประเภท (Classification) และการถดถอย (Regression) โดยใช้แนวคิดง่าย ๆ ว่าข้อมูลที่คล้ายกันมักจะอยู่ใกล้กัน กล่าวคือ เมื่อได้รับข้อมูล

ใหม่ตัวแบบจะพิจารณาค่าของข้อมูลข้างเคียง (neighbors) ที่ใกล้ที่สุดจำนวน k ตัว แล้วตัดสินใจจัดกลุ่มข้อมูลใหม่ตามเสียงข้างมากของเพื่อนบ้านเหล่านั้น ไม่มีขั้นตอนการเรียนรู้อย่างแท้จริง แต่จะอ้างอิงจากฐานข้อมูลเดิมโดยตรงทุกครั้งที่มีการทำนาย ทำให้มีความแม่นยำในชุดข้อมูลที่มีโครงสร้างชัดเจน แต่มีข้อจำกัดในด้านประสิทธิภาพเมื่อมีข้อมูลจำนวนมาก (Cover and Hart, 1967)

KNN จัดอยู่ในกลุ่มของวิธีการเรียนรู้แบบอาศัยตัวอย่าง (instance-based learning) หรือ lazy learning เนื่องจากไม่มีขั้นตอนการเรียนรู้แบบสร้างแบบจำลองล่วงหน้าอย่างชัดเจน แต่จะเก็บข้อมูลฝึกทั้งหมดไว้ และทำการคำนวณระยะห่างระหว่างข้อมูลใหม่กับข้อมูลในชุดฝึกทุกครั้งที่มีการทำนายผล แนวคิดของวิธีการจำแนกโดยอาศัยเพื่อนบ้านใกล้ที่สุด พารามิเตอร์ที่มีความสำคัญของ KNN คือจำนวนเพื่อนบ้าน k ซึ่งมีผลโดยตรงต่อพฤติกรรมของตัวแบบ หากกำหนดค่า k มีค่าน้อย ตัวแบบจะมีความไวต่อสัญญาณรบกวน (noise) และอาจเกิด overfitting ได้ง่าย ในทางตรงกันข้าม หากกำหนดค่า k มีค่ามากเกินไป เส้นขอบเขตการจำแนกจะเรียบขึ้น แต่ความสามารถในการแยกกลุ่มที่มีรูปแบบซับซ้อนอาจลดลง

นอกจากนี้ การเลือกตัวชี้วัดระยะห่าง (distance metric) เช่น Euclidean distance หรือ Manhattan distance รวมถึงการปรับสเกลของตัวแปร (feature scaling) มีความสำคัญอย่างยิ่งต่อประสิทธิภาพของอัลกอริทึม เนื่องจาก KNN อาศัยการคำนวณระยะห่างโดยตรง หากตัวแปรแต่ละตัวมีช่วงค่าที่แตกต่างกันมาก อาจทำให้ตัวแปรบางตัวมีอิทธิพลต่อผลการทำนายมากเกินไป

จุดเด่นของ K-Nearest Neighbors

1. เหมาะกับชุดข้อมูลขนาดเล็กไม่มาก
2. เป็นตัวแบบที่ทำงานไม่ซับซ้อนใช้หลักการเปรียบเทียบข้อมูลที่ใกล้เคียงกันในการทำนายผลลัพธ์
3. สามารถใช้กับปัญหา Multi-class Classification ได้
4. หากข้อมูลที่มีลักษณะใกล้เคียงกันมักมีผลลัพธ์คล้ายกัน KNN สามารถใช้ข้อมูลของเพื่อนบ้านใกล้เคียงช่วยในการทำนายได้ดี

ข้อจำกัดของ K-Nearest Neighbors

1. หากเลือกค่า K ไม่เหมาะสมอาจทำให้ตัวแบบทำนายผิดพลาดหรือประสิทธิภาพลดลง
2. ชุดข้อมูลที่มีหลาย Feature ซึ่งอาจทำให้การคำนวณความใกล้เคียงของข้อมูลมีประสิทธิภาพลดลง
3. ต้อง Preprocessing ข้อมูลตัวแบบไว้ก่อนขนาดของข้อมูลแต่ละ Feature จึงจำเป็นต้องทำ Scaling ก่อน Train ตัวแบบ
4. หากคลาส NED มีจำนวนมากกว่าคลาส D ตัวแบบอาจทำนายไปทางคลาสใหญ่ได้มากกว่าทำให้ Recall ของคลาส D ต่ำ

7. Feature Importance

Feature Importance เป็นเทคนิคที่คำนวณคะแนนสำหรับคุณลักษณะอินพุตทั้งหมดสำหรับแบบจำลองที่กำหนดคะแนนแสดงถึงความสำคัญของแต่ละคุณสมบัติ คะแนนที่สูงขึ้นหมายความว่าคุณลักษณะเฉพาะจะมีผลมากขึ้นต่อแบบจำลองที่ใช้ในการคาดการณ์ตัวแปรบางอย่าง (Shin, 2024) Feature Importance สามารถนำมาใช้เป็นแนวทางในการคัดเลือกตัวแปร (feature selection) โดยการพิจารณาตัดคุณลักษณะที่มีความสำคัญต่ำออกจากแบบจำลอง เพื่อลดความซับซ้อนของแบบจำลอง ลดปัญหา overfitting และเพิ่มประสิทธิภาพในการคำนวณ ทั้งนี้ วิธีการคำนวณค่า Feature Importance อาจแตกต่างกันไปตามชนิดของแบบจำลองที่ใช้ เช่น แบบจำลองเชิงต้นไม้จะคำนวณจากการลดค่าความไม่บริสุทธิ์ของโหนด (impurity reduction) ขณะที่บางวิธีเป็นวิธีเชิงอิสระจากตัวแบบ (model-agnostic) ซึ่งอาศัยการเปลี่ยนแปลงของประสิทธิภาพของแบบจำลองเมื่อมีการรบกวนค่าของคุณลักษณะนั้น



460115265

KU-thesis 6514401007 thesis / recv: 20052569 22:51:00 / seq: 158

8. Permutation Importance

Permutation Importance เป็นเทคนิคที่ใช้ในการเรียนรู้ของเครื่องเพื่อประเมินความสำคัญของคุณลักษณะต่างๆ ในแบบจำลองการคาดการณ์ แนวคิดพื้นฐานคือการวัดว่าประสิทธิภาพของตัวแบบลดลงมากน้อยเพียงใดเมื่อค่าของคุณลักษณะเฉพาะถูกสับสุ่มหรือสลับไปในขณะที่รักษาตัวแปรอื่นๆ ไว้ไม่เปลี่ยนแปลง (Galli, 2024)

จุดเด่นของ Permutation Importance คือเป็นวิธีการวิเคราะห์ความสำคัญของคุณลักษณะแบบไม่ขึ้นกับชนิดของแบบจำลอง (model-agnostic) สามารถประยุกต์ใช้กับแบบจำลองได้หลากหลายประเภท ไม่ว่าจะเป็นแบบจำลองเชิงเส้น แบบจำลองเชิงต้นไม้ หรือแบบจำลองเชิงซับซ้อนอื่นๆ โดยอาศัยเพียงค่าผลลัพธ์การทำนายและตัวชี้วัดประสิทธิภาพของแบบจำลองเท่านั้น อย่างไรก็ตาม การคำนวณ Permutation Importance มีข้อจำกัดในกรณีที่คุณลักษณะมีความสัมพันธ์กันสูง (correlated features) เนื่องจากการสับเปลี่ยนค่าของคุณลักษณะหนึ่งอาจยังสามารถทดแทนด้วยข้อมูลจากคุณลักษณะอื่นที่มีความสัมพันธ์ใกล้เคียงกันได้ ส่งผลให้ค่าความสำคัญที่คำนวณได้อาจต่ำกว่าความเป็นจริง

9. เมทริกซ์สหสัมพันธ์ (Correlation Matrix)

เมทริกซ์สหสัมพันธ์เป็นเทคนิคทางสถิติที่ใช้ในการประเมินความสัมพันธ์ระหว่างตัวแปรสองตัวในชุดข้อมูล โดยค่าสหสัมพันธ์มีค่าตั้งแต่ -1 ถึง +1 ถ้าค่าสหสัมพันธ์เข้าใกล้ -1 หรือ +1 แสดงว่าตัวแปรทั้งสองมีความสัมพันธ์เชิงเส้นตรงกันสูง แต่ถ้าค่าสหสัมพันธ์เข้าใกล้ 0 แสดงว่าตัวแปรทั้งสองมีความสัมพันธ์เชิงเส้นตรงกันน้อย (Wagavkar, 2024)

10. การทดสอบไคสแควร์ (Chi-square test)

การทดสอบไคสแควร์เป็นการทดสอบแบบไม่ใช้พารามิเตอร์สำหรับตัวแปรเชิงกลุ่ม การทดสอบนี้ใช้เพื่อพิจารณาว่าข้อมูลที่สังเกตได้แตกต่างจากข้อมูลที่คาดหวังอย่างมีนัยสำคัญและเพื่อพิจารณาว่าตัวแปรกลุ่มสองตัวมีความเกี่ยวข้องกันหรือไม่ (Turney, 2023)

วิธีคำนวณสถิติการทดสอบ

สถิติไคสแควร์เป็นสถิติการทดสอบความเป็นอิสระของตัวแปรเชิงกลุ่ม 2 ตัวดังนี้

$$\chi^2 = \sum_i \sum_j \frac{(O_{ij} - E_{ij})^2}{E_{ij}}$$

เมื่อ O_{ij} คือ จำนวนจริงที่สังเกตได้ (Observed frequency) ในตำแหน่งแถว i , คอลัมน์ j

E_{ij} คือ จำนวนที่คาดหวัง (Expected frequency) ในตำแหน่งแถว i , คอลัมน์ j

ค่า E_{ij} คำนวณได้จาก

$$E_{ij} = \frac{(\text{row total}_i \times \text{column total}_j)}{\text{total}}$$

เมื่อ row total_i คือ ผลรวมของแถวที่ i

column total_j คือ ผลรวมของคอลัมน์ที่ j

total = ผลรวมของข้อมูลทั้งหมดในตาราง

11. เกณฑ์ที่ใช้ในการเปรียบเทียบประสิทธิภาพของตัวแบบ

11.1 ความแม่นยำ (Accuracy)

เป็นเกณฑ์ที่บ่งบอกถึงความถูกต้องของตัวแบบในการทำนาย Accuracy สูงยิ่งแสดงให้เห็นถึงความสามารถของตัวแบบในการทำนายที่ถูกต้อง

$$\text{Accuracy} = \frac{\sum_{i=1}^3 TP_{ii}}{\text{Total Number of Predictions}} \times 100\%$$

เมื่อ $\sum_{i=1}^3 TP_{ii}$ คือ ผลรวมของ True Positives (TP) สำหรับแต่ละคลาส โดยที่ $i = 1, 2, 3$
Total number of predictions คือ จำนวนของตัวอย่างทั้งหมดในชุดข้อมูลทดสอบ

11.2 ความถูกต้อง (Precision)

การประเมินประสิทธิภาพของตัวแบบ เมื่อต้องการวัดประสิทธิภาพของตัวแบบในการทำนายคลาสบางคลาสที่สำคัญมาก (Positive class) ช่วยให้สามารถเข้าใจได้ว่าจากทั้งหมดที่ตัวแบบทำนายว่าเป็น Positive class ไปกี่เปอร์เซ็นต์ ยิ่งความถูกต้องสูงแสดงให้เห็นว่าตัวแบบทำนายที่เป็นจริงมากกว่าตัวแบบทำนายที่ผิดพลาด (False positives)

$$\text{Precision} = \frac{TP_{ii}}{TP_{ii} + \sum_{i \neq j} FP_{ij}} \times 100\%$$

เมื่อ True Positives (TP) คือ จำนวนตัวอย่างที่ตัวแบบทำนายถูกต้องว่าเป็นคลาส i โดยที่ $i = 1, 2, 3$
False Positives (FP) คือ จำนวนตัวอย่างที่ตัวแบบทำนายผิดว่าเป็นคลาส i แต่จริงแล้วเป็นคลาส j โดยที่ $j = 1, 2, 3$
 $\sum_{i \neq j} FP_{ij}$ คือผลรวมของ False Positives ทั้งหมดที่ไม่ใช่คลาส i

11.3 ความครอบคลุม (Recall) หรือ Sensitivity

เป็นการวัดความสามารถในการตรวจจับตัวอย่างที่เป็นบวกจริง (Positive class) เพื่อวัดว่าตัวแบบสามารถจับคลาสที่สนใจ Positive class ได้ทั้งหมดเท่าใดของจำนวนทั้งหมดที่เป็นจริง (Ground truth) ยิ่งค่า Recall สูง แสดงว่าตัวแบบสามารถตรวจจับคลาสที่สนใจได้ดีขึ้น

$$\text{Recall} = \frac{TP_{ii}}{TP_{ii} + \sum_{i \neq j} FN_{ij}} \times 100\%$$

เมื่อ True Positives (TP) คือ จำนวนตัวอย่างที่ตัวแบบทำนายถูกต้องว่าเป็นคลาส i โดยที่ $i = 1, 2, 3$
False Negatives (FN) คือ จำนวนตัวอย่างที่โมเดลทำนายผิดว่าเป็นคลาส j แต่จริงแล้วเป็นคลาส i โดยที่ $j = 1, 2, 3$

11.4 F1 Score

เป็นค่าความสมดุลระหว่างความแม่นยำ (Precision) และความครอบคลุม (Recall) เพื่อให้ได้มุมมองที่ครอบคลุมตั้งแต่ทั้งความแม่นยำและความครอบคลุมของตัวแบบในการจำแนก ยิ่ง F1 Score สูงยิ่งบ่งบอกถึงประสิทธิภาพของตัวแบบที่ดีขึ้นในการจำแนกคลาส

$$\text{F1 Score} = 2 \times \frac{\text{Precision} \times \text{Recall}}{\text{Precision} + \text{Recall}} \times 100\%$$

งานวิจัยที่เกี่ยวข้อง

Xin and Wei (2020) ได้ทำการวิเคราะห์และสรุปปัจจัยพยากรณ์โรค Prognostic Factors ที่มีผลต่อการรอดชีวิตและผลลัพธ์ทางคลินิกของผู้ป่วย Osteosarcoma โดยใช้วิธี Systematic review และ Meta-analysis จากงานวิจัยที่เกี่ยวข้องกับการรักษาและการพยากรณ์โรคในผู้ป่วย osteosarcoma เนื่องจาก osteosarcoma เป็นมะเร็งกระดูกชนิดร้ายแรงที่พบได้บ่อยในเด็กและวัยรุ่น และมีอัตราการกลับเป็นซ้ำและการแพร่กระจายสูง การระบุปัจจัยที่สัมพันธ์กับการพยากรณ์โรคสามารถช่วยสนับสนุนการวางแผนการรักษาและการติดตามผู้ป่วยได้อย่างเหมาะสม ผลการศึกษา

พบว่าปัจจัยที่มีความสัมพันธ์กับการพยากรณ์โรคอย่างมีนัยสำคัญ ได้แก่ อายุของผู้ป่วย ตำแหน่งของก้อนมะเร็ง ขนาดของเนื้องอก การแพร่กระจายของมะเร็งตั้งแต่เริ่มวินิจฉัย ระดับความรุนแรงของเนื้องอก (Tumor Grade) การตอบสนองต่อเคมีบำบัด และการผ่าตัดที่สามารถตัดก้อนมะเร็งออกได้อย่างสมบูรณ์ โดยเฉพาะผู้ป่วยที่มีการแพร่กระจายไปยังปอดหรือมีการตอบสนองต่อเคมีบำบัดต่ำมักมีอัตราการรอดชีวิตต่ำกว่ากลุ่มอื่น นอกจากนี้การตอบสนองต่อเคมีบำบัดก่อนการผ่าตัดยังถูกระบุว่าเป็นหนึ่งในตัวแปรสำคัญที่ใช้ประเมิน Prognosis ของผู้ป่วย Osteosarcoma

Navatha et al. (2021) ได้ทำการวิเคราะห์ความสำคัญของการพยากรณ์โรคของปัจจัยทางคลินิกและลักษณะทางเนื้อเยื่อในผู้ป่วยมะเร็งกระดูกหลังการให้เคมีบำบัดก่อนการผ่าตัด โดยเน้นที่การระบุตัวทำนายการอยู่รอดและผลลัพธ์ของการรักษา การวิจัยนี้ตรวจสอบข้อมูลจากศูนย์ดูแลผู้ป่วยตติยภูมิ โดยประเมินทั้งลักษณะทางคลินิกเบื้องต้นและการเปลี่ยนแปลงทางเนื้อเยื่อวิทยาของเนื้องอกหลังการให้เคมีบำบัด ผลการศึกษาที่สำคัญชี้ให้เห็นว่าปัจจัยเฉพาะ เช่น อัตราการตายของเนื้องอก การตอบสนองทางเนื้อเยื่อวิทยา ขนาดของเนื้องอก และระยะทางคลินิก มีความเกี่ยวข้องกับอย่างมากกับผลลัพธ์ของผู้ป่วย ผู้ป่วยที่มีอัตราการตายที่สูงขึ้นหลังการให้เคมีบำบัดและผู้ป่วยที่มีการตอบสนองทางเนื้อเยื่อวิทยาที่ดีโดยทั่วไปจะมีอัตราการรอดชีวิตที่เพิ่มขึ้น ซึ่งเน้นย้ำถึงพารามิเตอร์เหล่านี้ว่ามีความสำคัญต่อการพยากรณ์โรคและการวางแผนกลยุทธ์การรักษาในการดูแลมะเร็งกระดูก

Vangala et al. (2021) ได้ทำการวิเคราะห์ปัจจัยทางคลินิกและลักษณะทางเนื้อเยื่อที่มีความสำคัญต่อการทำนายการรอดชีวิตและผลลัพธ์ของการรักษาในผู้ป่วยมะเร็งกระดูกที่ได้รับเคมีบำบัดก่อนการผ่าตัด ผลการวิจัยพบว่าปัจจัยสำคัญ ได้แก่ อัตราการตายของเนื้องอก การตอบสนองทางเนื้อเยื่อวิทยา ขนาดของเนื้องอก และระยะทางคลินิก มีความสัมพันธ์อย่างมีนัยสำคัญกับผลลัพธ์ของผู้ป่วย โดยผู้ป่วยที่มีอัตราการตายของเนื้องอกสูงหลังการได้รับเคมีบำบัด และผู้ที่มีการตอบสนองทางเนื้อเยื่อที่ดี มักมีอัตราการรอดชีวิตที่เพิ่มขึ้น การศึกษานี้เน้นให้เห็นถึงความสำคัญของตัวทำนายทางคลินิกและพยาธิวิทยาในการประเมินการพยากรณ์โรคและการวางแผนการรักษาผู้ป่วยมะเร็งกระดูก

Jin et al. (2023) การศึกษานี้มีจุดมุ่งหมายเพื่อพัฒนาและทดสอบตัวแบบการเรียนรู้ของเครื่องจักรที่ใช้ Random Forest และ Logistic Regression เพื่อทำนายการตอบสนองที่ไม่ดีต่อเคมีบำบัดก่อนการผ่าตัดในผู้ป่วยมะเร็งเต้านม โดยทั่วไปแล้ว เคมีบำบัดก่อนการผ่าตัดมักใช้ก่อนการ

ผ่าตัดเพื่อลดขนาดของเนื้องอก แต่ผู้ป่วยบางรายไม่ตอบสนองอย่างมีประสิทธิภาพ การระบุผู้ป่วยที่มีการตอบสนองที่ไม่ดีในระยะเริ่มต้นสามารถช่วยชี้นำการตัดสินใจทางคลินิกได้ ทำให้สามารถกำหนดกลยุทธ์การรักษาเฉพาะบุคคลได้มากขึ้น ตัวแบบนี้ใช้ผู้ป่วยทั้งหมด 315 ราย ในกลุ่มประชากรตามรุ่น 1 ปี ผู้ป่วย 197 รายถูกแบ่งออกเป็นชุดฝึกอบรมในขณะที่ 87 รายอยู่ในชุดทดสอบ ได้ผลการทดสอบ ความจำเพาะ ความไว และ AUC คือ 0.800, 0.833 และ 0.810 ในรุ่น RF และ 0.520, 0.833 และ 0.653 ของ Logistic Regression ในกลุ่มประชากรตามรุ่น 5 ปี ผู้ป่วย 132 รายถูกแบ่งออกเป็นชุดการฝึกอบรมในขณะที่ 33 รายอยู่ในชุดทดสอบ ความจำเพาะ ความไว และ AUC คือ 0.800, 0.833 และ 0.810 ในรุ่น RF และ 0.520, 0.833 และ 0.653 ของ Logistic Regression ในกลุ่มประชากรตามรุ่น 5 ปี ผู้ป่วย 132 รายถูกแบ่งออกเป็นชุดการฝึกอบรมในขณะที่ 33 รายอยู่ในชุดทดสอบ ความจำเพาะ ความไว และ AUC คือ 0.882, 0.750 และ 0.829 ในรุ่น Random Forest และ 0.882, 0.688 และ 0.752 ของ Logistic Regression ในชุดการตรวจสอบภายนอกของแบบจำลอง Random Forest ความจำเพาะความไวและ AUC คือ 0.765, 0.812 และ 0.779 ของแบบจำลอง Logistic Regression ความจำเพาะ ความไว และ AUC คือ 0.833, 0.376 และ 0.619 สรุปคือแบบจำลอง Random Forest มีประสิทธิภาพที่ดีในการทำนายเหตุการณ์ในผู้ป่วย BC ที่มี SD และ PD หลัง NAC อาจเป็นประโยชน์ต่อผู้ป่วย BC ช่วยในการตรวจหาการกลับเป็นซ้ำของเนื้องอก

Hao et al. (2023) ได้ค้นหาแบบจำลองพยากรณ์โรคที่ดีที่สุดสำหรับผู้ป่วย osteosarcoma โดยมีผู้ป่วยจำนวน 2,912 รายจากฐานข้อมูล Surveillance, Epidemiology, and End Results Program (SEER) และผู้ป่วยอีก 225 รายจากมณฑลเหอเป่ย์ประเทศจีน การศึกษานี้ใช้แบบจำลอง Cox Proportional Hazards Model และอัลกอริทึมการเรียนรู้ของเครื่องแบบ tree-based จำนวน 3 วิธี ได้แก่ Survival Tree (ST), Random Survival Forest (RSF) และ Gradient Boosting Machine (GBM) เพื่อพัฒนาแบบจำลองพยากรณ์โรคโดยใช้วิธี 10-fold cross-validation จำนวน 200 รอบ นอกจากนี้ยังมีการเปรียบเทียบประสิทธิภาพของแบบจำลองในกลุ่มตัวแปรหลายปัจจัย (multivariable group) กับระบบ TNM ผลการศึกษาพบว่าอัตราการรอดชีวิตจำเพาะต่อมะเร็ง (Cancer-Specific Survival: CSS) ที่ 3 ปีและ 5 ปีในชุดพัฒนาแบบจำลองอยู่ที่ 72.71% และ 65.92% ตามลำดับ ความสามารถในการทำนายของกลุ่ม Multivariable มีประสิทธิภาพดีกว่าระบบ TNM อีกทั้ง calibration curves และความสอดคล้องของแบบจำลองในกลุ่ม Multivariable ก็เหนือกว่ากลุ่ม TNM เช่นกัน นอกจากนี้แบบจำลอง Cox และ RSF ยังมีประสิทธิภาพดีกว่า ST และ GBM



460115265

KU-thesis 6514401007 thesis / recv: 20052569 22:51:00 / seq: 158

Chu et al. (2026) ได้ทำการศึกษาศึกษาอัตราการรอดชีวิตโดยรวมและปัจจัยพยากรณ์โรคในผู้ป่วย Osteosarcoma โดยใช้ข้อมูลจากฐานข้อมูลระดับประเทศของไต้หวัน เนื่องจาก Osteosarcoma เป็นมะเร็งกระดูกที่มีความรุนแรงสูงและมีโอกาสเกิดการแพร่กระจายได้ง่าย การระบุปัจจัยที่มีผลต่อการรอดชีวิตจึงมีความสำคัญต่อการวางแผนการรักษาและการติดตามผู้ป่วยในระยะยาว งานวิจัยนี้รวบรวมข้อมูลผู้ป่วย Osteosarcoma จากหลายช่วงอายุและหลายรูปแบบการรักษาเพื่อนำมาวิเคราะห์ปัจจัยที่สัมพันธ์กับอัตราการรอดชีวิต ผลการศึกษาพบว่าปัจจัยที่มีผลต่อการพยากรณ์โรคอย่างมีนัยสำคัญ ได้แก่ อายุของผู้ป่วย ตำแหน่งของเนื้องอก การแพร่กระจายของมะเร็ง วิธีการรักษา และการตอบสนองต่อเคมีบำบัด โดยผู้ป่วยที่มีการแพร่กระจายของโรคตั้งแต่เริ่มวินิจฉัย โดยเฉพาะการแพร่กระจายไปยังปอด มีอัตราการรอดชีวิตต่ำกว่าผู้ป่วยที่ไม่มีการแพร่กระจายอย่างชัดเจน นอกจากนี้ผู้ป่วยที่ได้รับการรักษาแบบผสมผสาน เช่น การผ่าตัดร่วมกับเคมีบำบัด มีแนวโน้มที่จะมีอัตราการรอดชีวิตที่ดีกว่า

Thorn et al. (2026) ได้ศึกษาพัฒนาและเปรียบเทียบแบบจำลอง Machine Learning กับ Logistic Regression ในการทำนายการรอดชีวิตภายใน 5 ปี รวมถึงระบุปัจจัยสำคัญที่มีผลต่อการพยากรณ์โรค การศึกษานี้เป็นการศึกษาแบบ retrospective cohort โดยรวบรวมผู้ป่วยที่ได้รับการวินิจฉัยว่าเป็น soft tissue sarcoma ชนิด deep-seated และ high-grade บริเวณแขน ขา และผนังลำตัวในประเทศเดนมาร์กระหว่างปี ค.ศ. 2000 ถึง 2016 จำนวน 516 ราย และเปรียบเทียบ Logistic Regression กับแบบจำลอง Machine Learning จำนวน 4 วิธี รวมถึง Random Forest โดยใช้การแบ่งข้อมูลแบบ 70:30 สำหรับชุดฝึกอบรมและชุดทดสอบ ผลการศึกษาพบ Logistic Regression ให้ผลลัพธ์ดีกว่า โดยมีค่า AUC เท่ากับ 0.74 (95% CI 0.66 - 0.82) ขณะที่ Random Forest มีค่า AUC เท่ากับ 0.65 (95% CI 0.56–0.74) นอกจากนี้ Logistic Regression ยังมี sensitivity และ specificity สูงกว่า Random Forest ที่ค่า 0.65 เทียบกับ 0.59 และ 0.72 เทียบกับ 0.69 ตามลำดับ อย่างไรก็ตาม Random Forest มีค่า Brier score ต่ำกว่า (0.38 เทียบกับ 0.41) ซึ่งแสดงถึงความแม่นยำในการประมาณความน่าจะเป็นที่ดีกว่า



460115265

KU :Thesis 6514401007 thesis / recv: 20052569 22:51:00 / seq: 158

อุปกรณ์และวิธีการ

1. วัสดุและอุปกรณ์

1.1 คอมพิวเตอร์พกพา

2.2 โปรแกรมที่ใช้ในการสร้างตัวแบบในการทำนาย เช่น Jupyter Notebook

2. วิธีการดำเนินการ

2.1 จัดเตรียมข้อมูล Bone tumor จากเว็บไซต์ Memorial Sloan Kettering Cancer Center (MSKCC) เป็นชุดข้อมูลที่มีการเปิดเผยจำนวน 500 เรคคอร์ด เพื่อการวิเคราะห์

2.2 ทำการโหลดข้อมูลเข้า Jupyter Notebook ด้วยคำสั่ง `df=pd.read_csv('Bone_Tumor_Dataset.csv')` และทำการดูภาพรวมของข้อมูลด้วยคำสั่ง `df.info()`

	Patient ID	Sex	Age	Grade	Histological type	MSKCC type	Site of primary STS	Status (NED, AWD, D)	Treatment
0	STS_001	Female	63	High	pleiomorphic leiomyosarcoma	Leiomyosarcoma	parascapular	NED	Radiotherapy + Surgery
1	STS_002	Female	54	Intermediate	pleiomorphic leiomyosarcoma	MFH	left thigh	D	Surgery + Chemotherapy
2	STS_003	Male	22	Intermediate	synovial sarcoma	MFH	right buttock	D	Radiotherapy + Surgery
3	STS_004	Female	54	Intermediate	synovial sarcoma	Leiomyosarcoma	right thigh	NED	Radiotherapy + Surgery
4	STS_005	Male	63	High	pleiomorphic spindle cell undifferentiated	MFH	right parascapular	AWD	Radiotherapy + Surgery + Chemotherapy

ภาพที่ 8 การนำข้อมูลเข้า Jupyter Notebook

```

<class 'pandas.core.frame.DataFrame'>
RangeIndex: 500 entries, 0 to 499
Data columns (total 9 columns):
#   Column                Non-Null Count  Dtype
---  -
0   Patient ID            500 non-null    object
1   Sex                   500 non-null    object
2   Age                   500 non-null    int64
3   Grade                 500 non-null    object
4   Histological type     500 non-null    object
5   MSKCC type            500 non-null    object
6   Site of primary STS   500 non-null    object
7   Status (NED, AWD, D) 500 non-null    object
8   Treatment              500 non-null    object
dtypes: int64(1), object(8)
memory usage: 35.3+ KB

```

ภาพที่ 9 ภาพรวมชุดข้อมูล

2.3 ทำการตรวจสอบ Outliner ข้อมูลเชิงปริมาณ

2.4 ทำการตัดคอลัมที่ไม่ได้ใช้ออกและทำการแทนค่าข้อมูลที่เป็นข้อความให้เป็นตัวเลข เพราะตัวแบบบางตัวแบบไม่สามารถอ่านค่าที่เป็นข้อความได้

	Sex	Age	Grade	Histological type	MSKCC type	Site of primary STS	Status (NED, AWD, D)	Treatment
0	Female	63	High	pleiomorphic leiomyosarcoma	Leiomyosarcoma	parascapular	NED	Radiotherapy + Surgery
1	Female	54	Intermediate	pleiomorphic leiomyosarcoma	MFH	left thigh	D	Surgery + Chemotherapy
2	Male	22	Intermediate	synovial sarcoma	MFH	right buttock	D	Radiotherapy + Surgery
3	Female	54	Intermediate	synovial sarcoma	Leiomyosarcoma	right thigh	NED	Radiotherapy + Surgery
4	Male	63	High	pleiomorphic spindle cell undifferentiated	MFH	right parascapular	AWD	Radiotherapy + Surgery + Chemotherapy

ภาพที่ 10 การแปลงข้อมูลจากข้อความเป็นตัวเลข

2.5 ทำการ Exploratory Data Analysis (EDA) ประกอบไปด้วย

2.5.1 ตัวแปรตาม (Y) 1 แปร

2.5.2 ตัวแปรอิสระ (X_i) ทั้งหมด 7 ตัวแปร ดังนี้

ตารางที่ 2 แสดงลักษณะและรายละเอียดของตัวแปร

Variable	Label	Measurement scale	Exploratory
Y	Status (NED, AWD, D)	Nominal	0 – NED (no evidence of disease) 1 – AWD (alive with disease) 2 – D (dead)
X ₁	Sex	Nominal	0 – Male 1 – Female
X ₂	Age_Group	Ordinal	0 - Age <= 41 1 - Age 42 to 50 2 - Age 51 to 63 3 - Age 64 to 70 4 - Age >= 71
X ₃	Grade	Ordinal	0 – Intermediate 1 – High
X ₄	Histological type	Nominal	0 - Pleiomorphic leiomyosarcoma 1 - Synovial sarcoma 2 - Leiomyosarcoma 3 - Myxofibrosarcoma 4 - Undifferentiated - pleiomorphic 5 - Sclerosing epithelioid fibrosarcoma 6 - Pleiomorphic spindle cell undifferentiated 7 - Malignant solitary fibrous tumor 8 – Undifferentiated pleomorphic liposarcoma 9 - Myxoid fibrosarcoma 10 - Poorly differentiated synovial sarcoma

Variable	Label	Measurement scale	Exploratory
X ₅	MSKCC type	Nominal	11 - Pleomorphic sarcoma
			12 - Epithelioid sarcoma
			0 – MFH
			1 - Leiomyosarcoma
			2 - Synovial sarcoma
X ₆	Site of primary STS	Nominal	0 - Left thigh
			1 - Right thigh
			2 - Right buttock
			3 - Parascapular
			4 - Left biceps
			5 - Left buttock
X ₇	Treatment	Nominal	6 - Right parascapular
			0 - Radiotherapy + Surgery
			1 - Radiotherapy + Surgery + Chemotherapy
			2 - Surgery + Chemotherapy

2.6 ตรวจสอบความสัมพันธ์ของตัวแปรตาม (Y) และ ตัวแปรอิสระ (Xi) โดยทำการทดสอบไคสแควร์ (Chi-square) และ พิจารณาเมตริกซ์สหสัมพันธ์

Chi-square test for Sex vs Status:
 Chi-square Statistic: 166.90346211272865
 P-value: 5.719705879577386e-37
 มีความสัมพันธ์อย่างมีนัยสำคัญระหว่าง Sex และ Status.

Chi-square test for Age_Group vs Status:
 Chi-square Statistic: 45.804137828993504
 P-value: 2.589708641610115e-07
 มีความสัมพันธ์อย่างมีนัยสำคัญระหว่าง Age_Group และ Status.

Chi-square test for Grade vs Status:
 Chi-square Statistic: 86.36165120357788
 P-value: 1.7652479552831712e-19
 มีความสัมพันธ์อย่างมีนัยสำคัญระหว่าง Grade และ Status.


Chi-square test for Histological type vs Status:
 Chi-square Statistic: 161.19364963068688
 P-value: 2.6813882626473348e-22
 มีความสัมพันธ์อย่างมีนัยสำคัญระหว่าง Histological type และ Status.

Chi-square test for MSKCC type vs Status:
 Chi-square Statistic: 158.84184235732044
 P-value: 2.5900087294335426e-33
 มีความสัมพันธ์อย่างมีนัยสำคัญระหว่าง MSKCC type และ Status.

Chi-square test for Site of primary STS vs Status:
 Chi-square Statistic: 157.9785782806803
 P-value: 1.3553804004359652e-27
 มีความสัมพันธ์อย่างมีนัยสำคัญระหว่าง Site of primary STS และ Status.

Chi-square test for Treatment vs Status:
 Chi-square Statistic: 293.5074909012111
 P-value: 2.723934441252411e-62
 มีความสัมพันธ์อย่างมีนัยสำคัญระหว่าง Treatment และ Status.

ภาพที่ 11 ความสัมพันธ์ของตัวแปรตาม (Y) และ ตัวแปรอิสระ (Xi) โดย Chi-square



ภาพที่ 12 เมทริกซ์สหสัมพันธ์

2.7 ระบุตัวแปรที่เป็น Categorical และ Numeric

```
numeric_features = ['Age']
categorical_features = [
    'Sex',
    'Grade',
    'Histological type',
    'MSKCC type',
    'Site of primary STS',
    'Treatment']
```

ภาพที่ 13 ระบุตัวแปร

2.8 ทำการแบ่งข้อมูลเป็น 2 ส่วนคือตัวแปรอิสระ (X_i) และตัวแปรตาม (Y) และทำการแบ่ง Train set 80% และ Test set 20%

	Sex	Age	Grade	Histological type	MSKCC type	Site of primary STS	Treatment
0	Female	63	High	pleiomorphic leiomyosarcoma	Leiomyosarcoma	parascapular	Radiotherapy + Surgery
1	Female	54	Intermediate	pleiomorphic leiomyosarcoma	MFH	left thigh	Surgery + Chemotherapy
2	Male	22	Intermediate	synovial sarcoma	MFH	right buttock	Radiotherapy + Surgery
3	Female	54	Intermediate	synovial sarcoma	Leiomyosarcoma	right thigh	Radiotherapy + Surgery
4	Male	63	High	pleiomorphic spindle cell undifferentiated	MFH	right parascapular	Radiotherapy + Surgery + Chemotherapy
...	...	...	...	...	...	...	...
495	Male	31	Intermediate	epithelioid sarcoma	MFH	left thigh	Surgery + Chemotherapy
496	Male	41	High	poorly differentiated synovial sarcoma	MFH	right parascapular	Radiotherapy + Surgery + Chemotherapy
497	Female	60	Intermediate	pleomorphic sarcoma	Synovial sarcoma	right thigh	Radiotherapy + Surgery
498	Male	43	High	synovial sarcoma	MFH	right thigh	Radiotherapy + Surgery + Chemotherapy
499	Female	73	Intermediate	pleiomorphic leiomyosarcoma	Leiomyosarcoma	left biceps	Radiotherapy + Surgery

ภาพที่ 14 การแบ่งตัวแปรอิสระ (X_i)


Status (NED, AWD, D)	
NED	247
D	141
AWD	112

ภาพที่ 15 การแบ่งตัวแปรตาม (Y)

2.9 นำข้อมูลเข้าแบบจำลองทั้ง 5 วิธี ได้แก่ Logistic Regression, Random Forest, Artificial Neural Network, Support Vector Machine (SVM) และ K-Nearest Neighbors (KNN) ใช้ GridSearchCV ในการค้นหาค่า Hyperparameter ที่ดีที่สุดของตัวแบบและใช้วิธี Tomek Links ในการจัดการข้อมูลที่ไม่สมดุล

2.10 นำผลลัพธ์จากการทำนายมาเปรียบเทียบประสิทธิภาพของตัวแบบทั้ง 5 วิธี โดยใช้เกณฑ์พิจารณาจาก Accuracy, F1-score, Precision, Recall และ ROC AUC

2.11 ตรวจสอบว่าปัจจัยใดมีผลต่อ status (NED, AWD, D) ของผู้ป่วยมากที่สุด โดยพิจารณาจาก 2 เกณฑ์คือเมตริกซ์สหสัมพันธ์และ Feature Importance




ภาพที่ 16 แผนภาพการดำเนินงาน

ผลการวิจัย

1. ผลจากการวิเคราะห์ข้อมูลเชิงสำรวจ

จากภาพที่ 17 ทำการตรวจสอบ Outliers ชุดข้อมูลที่เป็นข้อมูลเชิงปริมาณซึ่งคือตัวแปรอายุ พบว่าอายุไม่มีค่า Outliers



ภาพที่ 17 กราฟตรวจสอบค่า Outliers ของอายุ

จากตารางที่ 3 จากการทดสอบ Chi-square ที่ระดับนัยสำคัญ 0.05 พบว่าทั้ง 7 ปัจจัยที่ส่งผลต่อผลลัพธ์การรักษามะเร็งกระดูก และที่ Sex พบว่าเพศหญิงมีสัดส่วน Status ในกลุ่ม NED สูงที่สุด ร้อยละ 69.3 ขณะที่เพศชายมีสัดส่วน Status ในกลุ่ม AWD และ D สูงกว่าเพศหญิงร้อยละ 49.0 และ 32.5 ตามลำดับที่ Age อายุมากกว่าเท่ากับ 71 มีสัดส่วน NED มากที่สุดอยู่ที่ร้อยละ 64.7 ในอายุ 42 ถึง 50 กลุ่ม AWD มากที่สุดที่ร้อยละ 30.7 และที่อายุน้อยกว่าเท่ากับ 41 มีสัดส่วนในกลุ่ม D มากที่สุดที่ร้อยละ 42.6 ที่ Grad ระดับความรุนแรง High สถานะผู้ป่วยในกลุ่ม NED และ D มีสัดส่วน ร้อยละ 63.1 และ 29.1 ตามลำดับและที่ Intermediate ในกลุ่ม AWD มากที่สุดร้อยละ 41.3 ที่ Histological type ชนิด Leiomyosarcoma มีสัดส่วน Status ในกลุ่ม NED มีมากที่สุดร้อยละ 81.4 ใน

กลุ่ม AWD ชนิด Undifferentiated pleomorphic liposarcoma มีสัดส่วนมากที่สุดร้อยละ 53.6 และในกลุ่ม D ชนิด Epithelioid sarcoma มีสัดส่วนมากที่สุดร้อยละ 60.0 ที่ MSKCC type พบว่า Leiomyosarcoma สัดส่วนสถานะผู้ป่วยในกลุ่ม NED สูงที่สุดร้อยละ 82.6 ที่ MFH ในกลุ่ม AWD มีมากที่สุดร้อยละ 43.1 และที่ Synovial sarcoma ในกลุ่ม D มีมากที่สุดร้อยละ 48.1 ที่ Site of primary STS ตำแหน่ง Parascapular พบว่าสถานะผู้ป่วยในกลุ่ม NED มากที่สุดคิดเป็นร้อยละ 82.1 ที่ตำแหน่ง Right Parascapular ในกลุ่ม AWD มากที่สุดร้อยละ 56.7 และตำแหน่ง Right buttock ในกลุ่ม D มีมากที่สุดร้อยละ 66.7 ที่ Treatment วิธีการรักษาด้วย Radiotherapy + Surgery มีมากที่สุดในกลุ่ม NED คิดเป็นร้อยละ 73.4 ที่ Radiotherapy + Surgery + Chemotherapy ในกลุ่ม AWD มีมากที่สุดร้อยละ 62.2 และวิธีการรักษาด้วย Surgery + Chemotherapy ในกลุ่ม D มีมากที่สุดร้อยละ 79.7 จากภาพที่ 18 เมื่อวิเคราะห์ความสัมพันธ์ของตัวแปรด้วย Correlation Matrix พบว่าปัจจัยที่ส่งผลต่อประสิทธิภาพการรักษาโรคเนื้องอกกระดูกของผู้ป่วยมากที่สุดคือ วิธีการรักษา (Treatment) คิดเป็นร้อยละ 49.2


ตารางที่ 3 ผลการแสดงความสัมพันธ์ระหว่างตัวแปรเชิงกลุ่มและการทดสอบความสัมพันธ์ระหว่างตัวแปรอิสระกับสถานะผู้ป่วยด้วยสถิติทดสอบ Chi-square และ Correlation Matrix (r_{y,x_i})

Variable	Status			P-value	r_{y,x_i}
	NED	AWD	D		
	(n= 247)	(n= 112)	(n= 141)		
Sex				5.72×10^{-37}	0.317
Female	208 (69.3)	14 (4.7)	78 (26.0)		
Male	39 (19.5)	98 (49.0)	63 (32.5)		
Age				2.59×10^{-7}	0.251
Age ≤ 41	43 (42.6)	15 (14.8)	43 (42.6)		
Age 42 to 50	30 (28.9)	32 (30.7)	42 (40.4)		
Age 51 to 63	59 (53.6)	26 (23.7)	25 (22.7)		
Age 64 to 70	51 (59.3)	18 (20.9)	17 (19.8)		
Age ≥ 71	64 (64.7)	21 (21.2)	14 (14.1)		

Variable	Status			P-value	r_{y,x_i}
	NED	AWD	D		
	(n= 247)	(n= 112)	(n= 141)		
Grade				1.77×10^{-19}	0.171
Intermediate	69 (31.7)	90 (41.3)	59 (27.0)		
High	178 (63.1)	22 (7.8)	82 (29.1)		
Histological type				2.68×10^{-22}	0.191
Pleiomorphic leiomyosarcoma	79 (75.9)	9 (8.7)	16 (15.4)		
Synovial sarcoma	34 (46.6)	2 (2.7)	37 (50.7)		
Leiomyosarcoma	35 (81.4)	2 (4.7)	6 (13.9)		
Myxofibrosarcoma	13 (32.5)	18 (45.0)	9 (22.5)		
Undifferentiated - pleiomorphic	8 (23.5)	16 (47.1)	10 (29.4)		
Sclerosing epithelioid	18 (54.6)	2 (6.0)	13 (39.4)		
Fibrosarcoma					
Pleiomorphic spindle cell	10 (34.5)	14 (48.3)	5 (17.2)		
Undifferentiated					
Malignant solitary fibrous tumor	15 (51.7)	6 (20.7)	8 (27.6)		
Undifferentiated pleomorphic	7 (25.0)	15 (53.6)	6 (21.4)		
Liposarcoma					
Myxoid fibrosarcoma	7 (25.9)	14 (51.9)	6 (22.2)		
Poorly differentiated synovial	6 (25.0)	8 (33.3)	10 (41.7)		
Sarcoma					
Pleomorphic sarcoma	9 (42.8)	6 (28.6)	6 (28.6)		
Epithelioid sarcoma	6 (40.0)	0 (0.0)	9 (60.0)		
MSKCC type				2.59×10^{-33}	0.025
MFH	68 (30.2)	97 (43.1)	60 (26.7)		
Leiomyosarcoma	119 (82.6)	7 (4.9)	18 (12.5)		
Synovial sarcoma	60 (45.8)	8 (6.1)	63 (48.1)		

Variable	Status			P-value	r_{y,x_i}
	NED	AWD	D		
	(n= 247)	(n= 112)	(n= 141)		
Site of primary STS				1.36×10^{-27}	0.038
Left thigh	53 (34.9)	64 (42.1)	35 (23.0)		
Right thigh	91 (67.4)	13 (9.6)	31 (23.0)		
Right buttock	17 (23.6)	7 (9.7)	48 (66.7)		
Parascapular	32 (82.1)	0 (0.0)	7 (17.9)		
Left biceps	27 (75.0)	3 (8.3)	6 (16.7)		
Left buttock	21 (58.3)	8 (22.2)	7 (19.5)		
Right parascapular	6 (20.0)	17 (56.7)	7 (23.3)		
Treatment				2.72×10^{-62}	0.492*
Radiotherapy + Surgery	215 (73.4)	18 (6.1)	60 (20.5)		
Radiotherapy + Surgery + Chemotherapy	24 (16.8)	89 (62.2)	30 (21.0)		
Surgery + Chemotherapy	8 (12.5)	5 (7.8)	51 (79.7)		


*กำหนดระดับนัยสำคัญ 0.05




ภาพที่ 18 กราฟแสดงความสัมพันธ์ระหว่างตัวแปรอิสระกับสถานะผู้ป่วย

2. ผลการวิเคราะห์ของตัวแบบ

จากภาพที่ 19 เมื่อพิจารณาจาก Feature Importance พบว่า Random Forest, Support Vector Machine, Artificial Neural Network และ K-Nearest Neighbors ปัจจัยที่ส่งผลต่อผลลัพธ์การรักษา มะเร็งกระดูกมากที่สุดคือ Treatment ส่วน Logistic Regression ปัจจัยที่ส่งผลต่อผลลัพธ์การรักษา มะเร็งกระดูกมากที่สุด คือ Histological type รองลงมาคือ Treatment เนื่องจากความแตกต่างของ Feature Importance ระหว่าง Logistic Regression และตัวแบบอื่นเกิดจาก ลักษณะการเรียนรู้ของแต่ละตัวแบบที่แตกต่างกัน โดย Logistic Regression ประเมินความสำคัญของตัวแปรจากความสัมพันธ์เชิงเส้น (Linear Relationship) ดังนั้น Logistic Regression จึงให้ความสำคัญกับ Histological type มากที่สุด เนื่องจากมีความสัมพันธ์เชิงเส้นกับสถานะของผู้ป่วยที่ชัดเจน (Hastie et al, 2009; Géron, 2019)



ภาพที่ 19 Feature Importance ของตัวแบบทั้ง 5 วิธี



จากตารางที่ 4 - 8 การสรุปผลจากการเปรียบเทียบประสิทธิภาพของตัวแบบทั้ง 5 พบว่า Artificial Neural Network มีประสิทธิภาพในการทำนายมากที่สุด เนื่องจากมีค่า Accuracy, Macro f1-score, Macro Precision และ Macro Recall ที่สูงกว่าตัวแบบอื่น รองลงมาเป็น Logistic Regression ตามด้วย Random Forest, Support Vector Machine และ K-Nearest Neighbors ตามลำดับ เมื่อพิจารณาประสิทธิภาพจาก ROC AUC จากภาพที่ 21 ROC AUC ของทั้ง 4 ตัวแบบ มีค่าเท่ากันคิดเป็นร้อยละ 89 มีเพียง K-Nearest Neighbors ที่มีค่า ROC AUC น้อยที่สุดคือร้อยละ 88 โดยที่ทุกวิธีแบบจำลองถือว่าเหมาะสมเนื่องจากพบว่า Training Accuracy, Test Accuracy และ ค่าเฉลี่ยของ cross-validation มีค่าสูงและใกล้เคียงกัน (Hastie et al, 2009; Géron, 2019)

ตารางที่ 4 ผลการทดสอบประสิทธิภาพของ Logistic Regression

Status (NED, AWD, D)	Precision	Recall	F1-score	Support
NED	0.81	0.86	0.83	56
D	0.71	0.60	0.65	20
AWD	0.83	0.83	0.83	24
Macro avg	0.78	0.76	0.77	100
Weighted avg	0.80	0.80	0.80	100
Train Score	0.73			
Accuracy	0.80			
Mean cross-validation	0.72			



460115265

KU-IThesis 6514401007 thesis / recv: 20052569 22:51:00 / seq: 158

ตารางที่ 5 ผลการทดสอบประสิทธิภาพของ Random Forest

Status (NED, AWD, D)	Precision	Recall	F1-score	Support
NED	0.81	0.92	0.81	56
D	0.63	0.60	0.62	20
AWD	0.83	0.83	0.73	24
Macro avg	0.76	0.75	0.75	100
Weighted avg	0.77	0.78	0.76	100
Train Score	0.74			
Accuracy	0.78			
Mean cross-validation	0.71			

ตารางที่ 6 ผลการทดสอบประสิทธิภาพของ Support Vector Machine


Status (NED, AWD, D)	Precision	Recall	F1-score	Support
NED	0.84	0.77	0.80	56
D	0.54	0.70	0.61	20
AWD	0.87	0.83	0.85	24
Macro avg	0.75	0.77	0.75	100
Weighted avg	0.73	0.75	0.74	100
Train Score	0.72			
Accuracy	0.77			
Mean cross-validation	0.69			

ตารางที่ 7 ผลการทดสอบประสิทธิภาพของ Artificial Neural Network


Status (NED, AWD, D)	Precision	Recall	F1-score	Support
NED	0.82	0.88	0.84	56
D	0.67	0.60	0.63	20
AWD	0.91	0.83	0.87	24
Macro avg	0.80	0.77	0.78	100
Weighted avg	0.81	0.81	0.81	100
Train Score	0.76			
Accuracy	0.81			
Mean cross-validation	0.72			

ตารางที่ 8 ผลการทดสอบประสิทธิภาพของ K-Nearest Neighbors


Status (NED, AWD, D)	Precision	Recall	F1-score	Support
NED	0.79	0.82	0.81	56
D	0.56	0.45	0.50	20
AWD	0.77	0.83	0.80	24
Macro avg	0.71	0.70	0.70	100
Weighted avg	0.71	0.72	0.72	100
Train Score	0.75			
Accuracy	0.75			
Mean cross-validation	0.69			




a) Logistic Regression




b) Random Forest



c) Support Vector Machine



d) Artificial Neural Network




e) K-Nearest Neighbors

ภาพที่ 21 ROC AUC ของตัวแบบทั้ง 5 วิธี

จากตารางที่ 9 และภาพที่ 22 เมื่อพิจารณาจากสัดส่วนของสถานะของผู้ป่วยและวิธีการรักษาพบว่าวิธีการรักษาด้วย Radiotherapy และ Surgery สถานะของผู้ป่วยส่วนใหญ่จะหายขาด (NED) คิดเป็นร้อยละ 73.38 และวิธีการรักษาด้วย Surgery และ Chemotherapy สถานะของผู้ป่วยจะผู้ป่วยจะตาย (D) คิดเป็นร้อยละ 79.69


ตารางที่ 9 ตารางแสดงร้อยละของวิธีการรักษากับสถานะของผู้ป่วย

Treatment	Status: NED (%)	Status: AWD (%)	Status: D (%)
Radiotherapy + Surgery	215 (73.38)	18 (6.14)	60 (20.48)
Radiotherapy + Surgery + Chemotherapy	24 (16.78)	89 (62.24)	30 (20.98)
Surgery + Chemotherapy	8 (12.50)	5 (7.81)	51 (79.69)



ภาพที่ 22 กราฟแสดงร้อยละของวิธีการรักษากับผลการรักษาของผู้ป่วย

จากภาพที่ 23 พิจารณาจาก Permutation Feature Importance พบว่าวิธีการรักษาด้วย Radiotherapy และ Surgery มีผลต่อสถานะของผู้ป่วยหายขาด (NED) มากที่สุด ส่วนวิธีการรักษาด้วย Radiotherapy, Surgery และ Chemotherapy มีผลต่อการกลับมาเป็นซ้ำหรือยังคงเป็นโรครอยู่ (AWD) และวิธีการรักษาด้วย Surgery และ Chemotherapy มีผลต่อการตายมากที่สุด (D)



ภาพที่ 23 Permutation Feature Importance ของวิธีการรักษากับสถานะของผู้ป่วย

3. วิจัย

จากการศึกษาครั้งนี้ใช้วิธีการทางสถิติและวิธีการเรียนรู้ของเครื่องจักรวิเคราะห์ข้อมูลพบว่าให้ผลลัพธ์สอดคล้องกันทั้ง 5 วิธี กล่าวคือปัจจัยที่ส่งผลต่อผลลัพธ์การรักษามะเร็งกระดูกคือวิธีการรักษา และวิธีการรักษาด้วย Radiotherapy และ Surgery มีผลต่อสถานะของผู้ป่วยหายขาด (NED) มากที่สุดซึ่งสอดคล้องกับงานวิจัยของ Chu et al. (2021) และวิธีการรักษาด้วย Surgery และ Chemotherapy มีผลต่อการตายมากที่สุด (D) นอกจากนี้จากวิธี Logistic Regression พบว่าปัจจัยที่ส่งผลต่อผลลัพธ์การรักษามะเร็งกระดูกมากที่สุดคือ ประเภทเนื้องอกกระดูกทางพยาธิสภาพซึ่งสอดคล้องกับงานวิจัยของ Navatha et al. (2021)

สรุปผลการทดลอง

ผลการทดสอบสมมติฐานโดยใช้สถิติทดสอบไคสแควร์ที่ระดับนัยสำคัญที่ 0.05 พบว่าทั้ง 7 ปัจจัยได้แก่ เพศ, อายุ, ระดับความรุนแรง, ประเภทเนื้องอกกระดูกทางพยาธิสภาพ, การแบ่งมะเร็งกระดูกโดย MSKCC, ตำแหน่งของมะเร็งกระดูก และ วิธีการรักษามีผลต่อสถานะของผู้ป่วย นอกจากนี้จากเมตริกซ์สหสัมพันธ์พบว่า วิธีการรักษามีผลต่อสถานะของผู้ป่วยมากที่สุดคิดเป็นร้อยละ 49.2 ซึ่งสอดคล้องกับ Feature Importance ของการวิเคราะห์ด้วยวิธี Random Forest, Support Vector Machine, Artificial Neural Network และ K-Nearest Neighbors พบว่า วิธีการรักษามีผลมากที่สุดมีเพียงตัวแบบ Logistic Regression เท่านั้นที่ประเภทเนื้องอกกระดูกทางพยาธิสภาพมีผลมากที่สุดรองลงมาเป็น วิธีการรักษา สรุปได้ว่า วิธีการรักษาส่งผลต่อผลลัพธ์การรักษามะเร็งกระดูกมากที่สุด ซึ่งผลการวิเคราะห์สอดคล้องกันทั้งวิธีการวิเคราะห์ทางสถิติและการวิเคราะห์การเรียนรู้ของเครื่องจักรและเมื่อทดสอบประสิทธิภาพของแบบจำลองทั้ง 5 พบว่า Artificial Neural Network มีประสิทธิภาพในการทำนายมากที่สุดเนื่องจากค่า Accuracy, Weighted F1-score, Weighted Precision และ Weighted Recall มากที่สุด รองลงมาเป็น Logistic Regression ตามด้วย Random Forest, Support Vector Machine, และ K-Nearest Neighbors ตามลำดับ จะเห็นได้ว่าจากผลการรักษาของผู้ป่วยที่หายขาดส่วนใหญ่จะใช้วิธีการรักษา Radiotherapy และ Surgery คิดเป็นร้อยละ 73.38 และจาก Permutation Feature Importance ด้วย Artificial Neural Network พบว่า วิธีการรักษาด้วย Radiotherapy และ Surgery ส่วนใหญ่ผลการรักษาผู้ป่วยหายขาดจากโรค

ตารางที่ 10 ตารางแสดงค่าวัดประสิทธิภาพของแต่ละตัวแบบ

Model	Weighted			Accuracy
	Precision	Recall	F1-Score	
Logistic Regression	0.80	0.80	0.80	0.80
Random Forest	0.78	0.78	0.78	0.78
SVM	0.79	0.77	0.78	0.77
ANN	0.81	0.81	0.81	0.81
KNN	0.74	0.75	0.74	0.75

ข้อเสนอแนะ

1. การวิจัยในครั้งนี้มีจำนวนชุดข้อมูลที่น้อยทำให้ตัวแบบเรียนรู้ไม่ครบรูปแบบ Variance สูงทำให้ผลแกว่งได้ง่าย ทำให้เกิดปัญหา Overfitting และ Underfitting ควรเพิ่มจำนวนชุดข้อมูล โดยเฉพาะคลาส D ที่มีจำนวน 141 เรคคอร์ดและ AWD มีจำนวน 112 เรคคอร์ดและชุดข้อมูลโดยรวมเพื่อให้ตัวแบบเรียนรู้ชุดข้อมูลได้ดีขึ้น

2. K-Nearest Neighbors ให้ประสิทธิภาพต่ำกว่าตัวแบบอื่นอาจเนื่องมาจากลักษณะของชุดข้อมูลที่มีหลาย Feature และมีข้อมูลเชิงหมวดหมู่ร่วมกับข้อมูลเชิงตัวเลขส่งผลให้การคำนวณความใกล้เคียงของข้อมูลทำได้ไม่ชัดเจนนอกจากนี้ค่า k ที่ใช้อาจจะไม่เหมาะสมที่สุด ความไม่สมดุลของจำนวนข้อมูลในแต่ละคลาสอาจส่งผลให้ตัวแบบมีแนวโน้มทำนายไปยังคลาสที่มีจำนวนข้อมูลมากกว่าทำให้ประสิทธิภาพตัวแบบโดยรวมลดลง

3. Artificial Neural Network ให้ประสิทธิภาพดีที่สุดในการทำนายเนื่องมาจากตัวแบบสามารถเรียนรู้รูปแบบของข้อมูลที่เกิดจากหลายปัจจัยร่วมกันได้ดีทำให้สามารถจำแนกข้อมูลในแต่ละกลุ่มได้อย่างมีประสิทธิภาพ นอกจากนี้ ANN ยังสามารถปรับพารามิเตอร์และน้ำหนักของ Feature ระหว่างการ Train เพื่อช่วยเพิ่มความแม่นยำของตัวแบบส่งผลให้มีผลลัพธ์โดยรวมดีกว่าตัวแบบอื่นได้

เอกสารและสิ่งอ้างอิง

- Alqahtani, S. A. M., Alobaid, H. M., Alshammari, J., Alqarzae, S. A., Aloyouni, S. Y., Al-Eidan, A. A., Alhamad, S., Almiman, A., Alkhulaifi, F. M., & Alomar, S. (2024). Feature importance and model performance for prediabetes prediction: A comparative study. *Journal of King Saud University - Science*, 36(11). <https://doi.org/10.1016/j.jksus.2024.103583>
- Altmann, A., Tolosi, L., Sander, O., & Lengauer, T. (2010). Permutation importance: a corrected feature importance measure. *Bioinformatics*, 26(10), 1340-1347. <https://doi.org/10.1093/bioinformatics/btq134>
- Australia, H. (2023). Bone cancer. <https://www.healthdirect.gov.au/bone-cancer>
- Avanti Shrikumar, P. G., Anshul Kundaje. (2017). Learning Important Features Through Propagating Activation Differences. <https://doi.org/doi.org/10.48550/arXiv.1704.02685>
- Babu Vimala, B., Srinivasan, S., Mathivanan, S. K., Mahalakshmi, Jayagopal, P., & Dalu, G. T. (2023). Detection and classification of brain tumor using hybrid deep learning models. *Sci Rep*, 13(1), 23029. <https://doi.org/10.1038/s41598-023-50505-6>
- Baladram, S. (2024). Oversampling and Undersampling, Explained: A Visual Guide with Mini 2D Dataset. Retrieved October 26 from <https://towardsdatascience.com/oversampling-and-undersampling-explained-a-visual-guide-with-mini-2d-dataset-1155577d3091/>
- Bisong, E., Jibril, N., Premnath, P., Buligwa, E., Oboh, G., & Chukwuma, A. (2024). Predicting high blood pressure using machine learning models in low- and middle-income countries. *BMC Med Inform Decis Mak*, 24(1), 234. <https://doi.org/10.1186/s12911-024-02634-9>
- Board, W. C. o. T. E. (2020). Soft Tissue and Bone Tumours. International Agency for Research on Cancer. <https://books.google.co.th/books?id=kaR9zQEACAAJ>
- Cahyani, N., & Irsyada, R. (2025). Performance Comparison of SelectKBest and Permutation Importance in Feature Selection for Diabetes Prediction. *Brilliance: Research of Artificial Intelligence*, 5(1), 529-541. <https://doi.org/10.47709/brilliance.v5i1.6507>
- Center, M. S. K. C. (2024). Bone Cancer. Retrieved November 14 from <https://www.mskcc.org/search#q=bone%20tumor&t=All&sort=relevancy>
- Chu, H. Y., Shen, X. H., Lin, C. N., Lee, C. C., Chen, Y. C., Chen, Y. J., Lin, Y. C., & Chang, S. H. (2026). Overall Survival and Prognostic Factors in Osteosarcoma: A Nationwide Cohort

- Study from Taiwan. *Life (Basel)*, 16(2). <https://doi.org/10.3390/life16020288>
- Claude Sammut, & Webb, G. I. (2011). *Encyclopedia Machine Learning*. Springer Science+Business Media. <https://doi.org/10.1007/978-0-387-30164-8>
- Cover, T., & Hart, P. (1967). Nearest neighbor pattern classification. *IEEE Transactions on Information Theory*, 13(1), 21 - 27. <https://doi.org/10.1109/TIT.1967.1053964>
- Elias, F., Reza, M. S., Mahmud, M. Z., & Islam, S. (2025). Machine Learning Meets Transparency in Osteoporosis Risk Assessment: A Comparative Study of ML and Explainability Analysis. *arXiv*. <https://doi.org/10.48550/arXiv.2505.00410>
- Elseiver, O. f. (2019). Bone tumors: Pathology review. In.
- Galli, S. (2024, Jan 11). Understanding Permutation Feature Importance for Model Interpretation. <https://www.blog.trainindata.com/permutation-feature-importance/>
- GeeksforGeeks. (2024). Logistic Regression in Machine Learning. <https://www.geeksforgeeks.org/understanding-logistic-regression/>
- Géron, A. (2019). *Hands-On Machine Learning with Scikit-Learn, Keras, and TensorFlow: Concepts, Tools, and Techniques to Build Intelligent Systems* (r. Edition, Ed.). O'Reilly Media.
- Ginting, J. B., Suci, T., Ginting, C. N., & Girsang, E. (2023). Early detection system of risk factors for diabetes mellitus type 2 utilization of machine learning-random forest. *J Family Community Med*, 30(3), 171-179. https://doi.org/10.4103/jfcm.jfcm_33_23
- Hao, Y., Liang, D., Zhang, S., Wu, S., Li, D., Wang, Y., Shi, M., & He, Y. (2023). Machine learning for predicting the survival in osteosarcoma patients: Analysis based on American and Hebei Province cohort. *Biomol Biomed*, 23(5), 883-893. <https://doi.org/10.17305/bb.2023.8804>
- Hastie, T., Tibshirani, R., & Friedman, J. (2009). *The Elements of Statistical Learning*. Springer. <https://link.springer.com/book/10.1007/978-0-387-84858-7>
- Hayashi, K., & Tsuchiya, H. (2022). The role of surgery in the treatment of metastatic bone tumor. <https://doi.org/10.1007/s10147-022-02144-6>
- Institute, N. C. (2018). Primary Bone Cancer. Retrieved May 5, 2026 from <https://www.cancer.gov/types/bone/bone-fact-sheet>
- Jin, Y., Lan, A., Dai, Y., Jiang, L., & Liu, S. (2023). Development and testing of a random forest-

based machine learning model for predicting events among breast cancer patients with a poor response to neoadjuvant chemotherapy. *Eur J Med Res*, 28(1), 394.

<https://doi.org/10.1186/s40001-023-01361-7>

Krawczyk, B. (2016). Learning from imbalanced data: open challenges and future directions.

Progress in Artificial Intelligence, 5(4), 221-232. <https://doi.org/10.1007/s13748-016-0094-0>

Kumar, D. (2024, July 18). Understanding Feature Importance in Logistic Regression Models.

<https://www.geeksforgeeks.org/understanding-feature-importance-in-logistic-regression-models/>

La Cava, W. B., C.; Moore, J. H.; Pendergrass, S. A. (2020). Interpretation of machine learning predictions for patient outcomes in electronic health records AMIA Annual Symposium Proceedings, 2019, 572–581. <https://www.ncbi.nlm.nih.gov/pmc/articles/PMC7153071/>

Lematre, G., & Aridas, F. N. a. C. K. (2017). Imbalanced-learn: A Python Toolbox to Tackle the Curse of Imbalanced Datasets in Machine Learning [16-365]. *Journal of Machine Learning Research*, 18, 1-5. <https://imbalanced-learn.org/stable/introduction.html>

Li, H., Liu, R. B., Long, C. M., Teng, Y., Cheng, L., & Liu, Y. (2022). Development and Validation of a New Multiparametric Random Survival Forest Predictive Model for Breast Cancer Recurrence with a Potential Benefit to Individual Outcomes. *Cancer Manag Res*, 14, 909-923. <https://doi.org/10.2147/CMAR.S346871>

Logunova, I. (2022). Random Forest Classifier: Basic Principles and Applications. Retrieved june 23 from <https://serokell.io/blog/random-forest-classification>

Lucas, D. R., Kshirsagar, M. P., Biermann, J. S., Hamre, M. R., Thomas, D. G., Schuetze, S. M., & Baker, L. H. (2008). Histologic alterations from neoadjuvant chemotherapy in high-grade extremity soft tissue sarcoma: clinicopathological correlation. *Oncologist*, 13(4), 451-458. <https://doi.org/10.1634/theoncologist.2007-0220>

Meyers, P. A., Heller, G., & Vlamis, V. (1993). Osteosarcoma of the extremities: Chemotherapy experience at Memorial Sloan-Kettering. In G. B. Humphrey, H. S. Koops, W. M. Molenaar, & A. Postma (Eds.), *Osteosarcoma in Adolescents and Young Adults: New Developments and Controversies* (pp. 309-322). Springer US. https://doi.org/10.1007/978-1-4615-3518-8_37

- S. Gutta, J. A., M.S. Shiroishi, D. Hwang, and K.S. Nayak. (2018). Improved Glioma Grading Using Deep Convolutional Neural Networks. *American Journal of Neuroradiology*, 39(3), 552–557. <https://doi.org/10.3174/ajnr.A5543>
- Sahu, K. (2018). ARTIFICIAL NEURAL NETWORKS AND APPLICATIONS:A REVIEW. *International Journal of Creative Research Thoughts (IJCRT)*, 6.
- Sayad, D. S. (2018). Artificial Neural Network. https://www.saedsayad.com/artificial_neural_network.htm
- Sbaraglia, M., Bellan, E., & Dei Tos, A. P. (2021). The 2020 WHO Classification of Soft Tissue Tumours: news and perspectives. *Pathologica*, 113(2), 70-84. <https://doi.org/10.32074/1591-951X-213>
- Shin, T. (2024, Nov 07). Understanding Feature Importance in Machine Learning. <https://builtin.com/data-science/feature-importance>
- SJ, R., R, A., M, K., & MT, S. (2018). Limb-sparing surgery plus radiotherapy results in superior survival: an analysis of patients with high-grade, extremity soft-tissue sarcoma from the NCDB and SEER. *Cancer*, 124(22), 4402–4410. <https://doi.org/10.1002/cncr.31665>
- Society, A. C. (2023). Survival Rates for Bone Cancer. <https://www.cancer.org/cancer/types/bone-cancer/detection-diagnosis-staging/survival-statistics.html#what-is-a-5-year-relative-survival-rate?>
- Surgeons, A. A. o. O. (2020). Bone Tumor. <https://orthoinfo.aaos.org/en/diseases--conditions/bone-tumor/>
- Sutradhar, R., & Barbera, L. (2020). Comparing an Artificial Neural Network to Logistic Regression for Predicting ED Visit Risk Among Patients With Cancer: A Population-Based Cohort Study. *J Pain Symptom Manage*, 60(1), 1-9. <https://doi.org/10.1016/j.jpainsymman.2020.02.010>
- Tanmoymishra. (2024, Jun 04). Understanding Feature Importance and Visualization of Tree Models. <https://www.geeksforgeeks.org/understanding-feature-importance-and-visualization-of-tree-models/>
- Thachai, W. (2016, Dec 22). จัดการข้อมูล Imbalanced ใน Scikit-learn. <https://medium.com/espressoofx-notebook/%E0%B8%88%E0%B8%B1%E0%B8%94%E0%B8%81%E0%B8%B2%E0%B>

8%A3%E0%B8%82%E0%B9%89%E0%B8%AD%E0%B8%A1%E0%B8%B9%E0%B8%A5-imbalanced-%E0%B9%83%E0%B8%99-scikit-learn-c22f4c18ebb5

Thorn, A., Lavery, J. A., Baad-Hansen, T., Forsberg, J. A., Petersen, M. M., & Holm, C. E. (2026). Machine learning and logistic regression in estimating survival in patients with high-malignant deep-seated soft tissue sarcomas: development and analysis based on a population-based retrospective cohort. *Acta Orthop*, 97, 185-193.

<https://doi.org/10.2340/17453674.2026.45509>

Turney, S. (2023). Chi-Square Test of Independence | Formula, Guide & Examples. Retrieved 2022 from <https://www.scribbr.com/statistics/chi-square-test-of-independence/>

Vangala, N., Uppin, S. G., Rao, K. N., Chandrasekhar, P., & Gundeti, S. (2021). Prognostic Significance of Clinical and Post-Neoadjuvant Chemotherapy Associated Histomorphological Parameters in Osteosarcoma: A Retrospective Study from a Tertiary Care Center. *Indian Journal of Medical and Paediatric Oncology*, 42(06), 547-553.

<https://doi.org/10.1055/s-0041-1740113>

vijayendraprasad. (2024, Apr 05). Feature Importance with Random Forests.

<https://www.geeksforgeeks.org/feature-importance-with-random-forests/>

Wagavkar, S. (2024). Introduction to the Correlation Matrix. Retrieved Nov 20 from <https://builtin.com/data-science/correlation-matrix>

Walczak, S., & Cerpa, N. (2003). Artificial Neural Networks. In (pp. 631-645).

<https://doi.org/10.1016/B0-12-227410-5/00837-1>

Wang, Y., Cui, J., Chen, J., Wan, J., Liang, Y., Qi, M., Wang, X., Zhang, L., & Lin, K. (2022).

Novel bone tumor cell targeting nanosystem for chemo-photothermal therapy of malignant bone tumors. *Chemical engineering journal* (Lausanne, Switzerland : 1996), 446, 136905.

<https://doi.org/10.1016/j.cej.2022.136905>

Wang, Z., Geest, I. C. V., Leeuwenburgh, S. C., & van den Beucken, J. J. (2023). Bifunctional bone substitute materials for bone defect treatment after bone tumor resection. *Mater Today Bio*, 23, 100889. <https://doi.org/10.1016/j.mtbio.2023.100889>

Xin, S., & Wei, G. (2020). Prognostic factors in osteosarcoma: A study level meta-analysis and systematic review of current practice. *J Bone Oncol*, 21, 100281.

<https://doi.org/10.1016/j.jbo.2020.100281>

ยุทธ ไถยวรรณ. (2555). หลักการและการใช้การวิเคราะห์การถดถอยโลจิสติกสำหรับการวิจัย.

วารสารวิจัยมหาวิทยาลัยเทคโนโลยีราชมงคลศรีวิชัย, 4(1), 1-12.

วานิชย์บัญชา, ก. (2554). การวิเคราะห์สถิติขั้นสูงด้วย SPSS for Windows (พ. 9, Ed.). ภาควิชาสถิติ

คณะพาณิชยศาสตร์และการบัญชี จุฬาลงกรณ์มหาวิทยาลัย.



460115265

KU iThesis 6514401007 thesis / recv: 20052569 22:51:00 / seq: 158

ภาคผนวก

 KU IThesis 6514401007 thesis / recv: 20052569 22:51:00 / seq: 158
460115265

1. ภาพรวมของชุดข้อมูลด้วยคำสั่ง df.info() และทำการตรวจสอบการกระจายตัวของชุดข้อมูล

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 500 entries, 0 to 499
Data columns (total 9 columns):
#   Column                Non-Null Count  Dtype
---  ---
0   Patient ID            500 non-null    object
1   Sex                   500 non-null    object
2   Age                   500 non-null    int64
3   Grade                 500 non-null    object
4   Histological type     500 non-null    object
5   MSKCC type            500 non-null    object
6   Site of primary STS   500 non-null    object
7   Status (NED, AWD, D)  500 non-null    object
8   Treatment              500 non-null    object
dtypes: int64(1), object(8)
memory usage: 35.3+ KB
```

ภาพภาคผนวกที่ 1 ภาพรวมของชุดข้อมูล

```
#การกระจายตัวของอายุ จัดกลุ่มอายุ
plt.hist(df['Age'], bins=30, edgecolor='black')#กราฟฮิสโตแกรมการกระจายตัว'age' ใน DataFrame 'df' แบ่งเป็น 30 ช่อง
plt.title('Age Distribution')
plt.xlabel('Age')
plt.ylabel('Count')
plt.show()
```

ภาพภาคผนวกที่ 2 การตรวจสอบการกระจายของอายุ

2. ตรวจสอบความสัมพันธ์ระหว่างตัวแปรอิสระกับตัวแปรตามด้วย Chi-square Test และ correlation matrix

```
from scipy.stats import chi2_contingency
import pandas as pd

# ตัวอย่างการทดสอบ Chi-square สำหรับตัวแปรที่ไม่มีความสัมพันธ์
variables = ['Sex', 'Age_Group', 'Grade', 'Histological type', 'MSKCC type', 'Site of primary STS', 'Treatment']
for var in variables:
    contingency_table = pd.crosstab(df[var], df['Status (NED, AWD, D)'])
    chi2, p_value, dof, expected = chi2_contingency(contingency_table)

    # แสดงผลลัพธ์
    print(f"Chi-square test for {var} vs Status:")
    print(f"Chi-square Statistic: {chi2}")
    print(f"P-value: {p_value}")

    # การตัดสินใจ
    if p_value < 0.05:
        print(f"มีความสัมพันธ์อย่างมีนัยสำคัญระหว่าง {var} และ Status.\n")
    else:
        print(f"ไม่มีความสัมพันธ์อย่างมีนัยสำคัญระหว่าง {var} และ Status.\n")
```

ภาพภาคผนวกที่ 3 ตรวจสอบความสัมพันธ์ระหว่างตัวแปรด้วย Chi-square Test

```
# คำนวณ Pearson Correlation ระหว่างทุกตัวแปรที่เป็นตัวเลข
correlation_matrix = df.corr()
# แสดงตารางความสัมพันธ์
print(correlation_matrix)
# ถ้าต้องการแสดงผลในรูปแบบ Heatmap ด้วย Seaborn
plt.figure(figsize=(10, 8)) # กำหนดขนาดกราฟ
sns.heatmap(correlation_matrix, annot=True, cmap='coolwarm', fmt='.2f', linewidths=0.5)
plt.title('Correlation Matrix')
plt.show()
```

ภาพภาคผนวกที่ 4 ตรวจสอบความสัมพันธ์ระหว่างตัวแปรด้วย correlation matrix

3.คำสั่งสร้างตัวแบบทำนายทั้ง 5 วิธีปัจจัยที่ส่งผลต่อผลลัพธ์การรักษามะเร็งกระดูก

```
%matplotlib inline
import pandas as pd
import numpy as np
import matplotlib.pyplot as plt
import seaborn as sns
from sklearn import metrics
from sklearn.preprocessing import StandardScaler
from sklearn.model_selection import train_test_split
from sklearn.neural_network import MLPClassifier
from sklearn.ensemble import RandomForestClassifier
from sklearn.linear_model import LogisticRegression
from sklearn.linear_model import LinearRegression
from sklearn.neighbors import KNeighborsClassifier
from sklearn.model_selection import RandomizedSearchCV
from sklearn.svm import SVC
from keras.models import Sequential
from keras.layers import Dense
from keras.optimizers import Adam
from sklearn.metrics import mean_squared_error
from sklearn.metrics import roc_auc_score
from sklearn.metrics import roc_curve
```

ภาพภาคผนวกที่ 5 คำสั่งเริ่มต้นก่อนสร้างตัวแบบ

```
df=pd.read_csv('Bone_Tumor_Dataset.csv')
df.head(5)
```

ภาพภาคผนวกที่ 6 คำสั่งนำเข้าข้อมูล


```

numeric_features = ['Age']
categorical_features = [
    'Sex',
    'Grade',
    'Histological type',
    'MSKCC type',
    'Site of primary STS',
    'Treatment']

X = df.loc[:, ~(df.columns == 'Status (NED, AWD, D)')]
X

```

ภาพภาคผนวกที่ 7 คำสั่งจัดหมวดหมู่คลาส

```

X = df.loc[:, ~(df.columns == 'Status (NED, AWD, D)')]
X
y = df['Status (NED, AWD, D)']
y.value_counts()

```

ภาพภาคผนวกที่ 8 คำสั่งแบ่งตัวแปรอิสระและตัวแปรตาม

```

from sklearn.preprocessing import OneHotEncoder
preprocessor = ColumnTransformer(
    transformers=[
        ('num', StandardScaler(), numeric_features),
        ('cat', OneHotEncoder(handle_unknown='ignore'), categorical_features)
    ]
)

```

ภาพภาคผนวกที่ 9 คำสั่งแบ่ง Train Test Split และ OneHotEncoder

```

from sklearn.model_selection import GridSearchCV
# โมเดล
logreg = LogisticRegression(class_weight='balanced', max_iter=5000)

param_grid_lr = {
    'C': [0.01, 0.1, 1, 10, 100],
    'solver': ['lbfgs', 'liblinear', 'saga']
}
pipe = Pipeline(steps=[
    ('prep', preprocessor),
    ('clf', logreg)
])
grid_lr = GridSearchCV(
    estimator=pipe,
    param_grid={'clf__' + k: v for k, v in param_grid_lr.items()},
    cv=3,
    scoring='f1_macro',
    n_jobs=-1
)
grid_lr.fit(X_train, y_train)
best_model_lr = grid_lr.best_estimator_
y_pred = best_model_lr.predict(X_test)
y_pred[:10]
print("Test Accuracy:", best_model_lr.score(X_test, y_test))
print("Best Parameters:", grid_lr.best_params_)
print("Best Score:", grid_lr.best_score_)

```

ภาพภาคผนวกที่ 10 คำสั่ง GridSearchCV เพื่อหาพารามิเตอร์ Logistic Regression

```

best_params_lr = grid_lr.best_params_
log = LogisticRegression(
    class_weight='balanced',
    C=best_params_lr['clf__C'],
    solver=best_params_lr['clf__solver'],
    max_iter=1000
)

```

```

from imblearn.under_sampling import TomekLinks
from imblearn.pipeline import Pipeline as ImbPipeline
logreg = ImbPipeline(steps=[
    ('prep', preprocessor),
    ('resample', TomekLinks()),
    ('clf', log)
])
logreg.fit(X_train, y_train)
y_pred=logreg.predict(X_test)
print('Accuracy of logistic regression classifier on test set: {:.2f}'.format(logreg.score(X_test, y_test)))
from sklearn.model_selection import cross_val_score
y_pred[:10]

```

ภาพภาคผนวกที่ 11 คำสั่งสร้างตัวแบบ Logistic Regression และทำนายผลลัพธ์

```

from sklearn.metrics import classification_report
print(classification_report(y_test,y_pred))

# คำนวณ ROC AUC โดยใช้ OvR (One-vs-Rest)
logit_roc_auc = roc_auc_score(y_test, logreg.predict_proba(X_test), multi_class="ovr", average="weighted")
print(f"Weighted ROC AUC (OvR): {logit_roc_auc:.2f}")
# คำนวณค่า fpr และ tpr สำหรับแต่ละคลาส
fpr = {}
tpr = {}
thresholds = {}
classes = logreg.classes_
plt.figure(figsize=(8, 6))
for i, c in enumerate(classes):
    # สร้าง ROC curve สำหรับแต่ละคลาส
    fpr[c], tpr[c], thresholds[c] = roc_curve(y_test == c, logreg.predict_proba(X_test)[: , i])
    plt.plot(fpr[c], tpr[c], label=f'Class {c} (area = {roc_auc_score(y_test == c, logreg.predict_proba(X_test)[: , i]):.2f})')
# Plot settings
plt.plot([0, 1], [0, 1], 'r--')
plt.xlim([0.0, 1.0])
plt.ylim([0.0, 1.05])
plt.xlabel('False Positive Rate')
plt.ylabel('True Positive Rate')
plt.title('Receiver Operating Characteristic of Logistic Regression (ROC) Curve')
plt.legend(loc="lower right")
plt.savefig('Log_Roc')
plt.show()

```

ภาพภาคผนวกที่ 12 คำสั่งตรวจสอบประสิทธิภาพ Logistic Regression

```

clf = logreg.named_steps['clf']
feature_names = logreg.named_steps['prep'].get_feature_names_out()

importance = np.mean(np.abs(clf.coef_), axis=0)

df_imp = pd.DataFrame({
    'feature_full': feature_names,
    'importance': importance
})

def original_name(x):
    x = x.replace("num_", "").replace("cat_", "")
    return x.split("_")[0]

df_imp['feature'] = df_imp['feature_full'].apply(original_name)

feature_importance = df_imp.groupby('feature')['importance'].sum()
feature_importance = feature_importance.sort_values(ascending=False)
# gradient color
cmap = plt.get_cmap("coolwarm")
norm = plt.Normalize(
    vmin=feature_importance.min(),
    vmax=feature_importance.max()
)

plt.figure(figsize=(10,6))
ax = plt.gca()

bars = ax.bar(
    feature_importance.index,
    feature_importance.values,
    color=cmap(norm(feature_importance.values))
)

# ใส่ตัวเลขบนแท่งกราฟ
for bar in bars:
    height = bar.get_height()
    ax.text(
        bar.get_x() + bar.get_width()/2,
        height,
        f'{height:.2f}',
        ha='center',
        va='bottom',
        fontsize=10
    )

plt.title("Feature Importance from Logistic Regression")
plt.xlabel("Variables")
plt.ylabel("Importance")

# colorbar
sm = plt.cm.ScalarMappable(cmap=cmap, norm=norm)
sm.set_array([])

cbar = plt.colorbar(sm, ax=ax)
cbar.set_label("Importance")

plt.xticks(rotation=45, ha='right')
plt.tight_layout()
plt.show()

```

ภาพภาคผนวกที่ 13 คำสั่ง Feature Importance ของ Logistic Regression

```

# Grid Searchcv
rf = RandomForestClassifier(class_weight='balanced')

# parameter grid
param_grid_rf = {
    'n_estimators': [50, 100, 200, 500],
    'max_depth': [None, 10, 20, 30],
    'min_samples_split': [2, 5, 10],
    'min_samples_leaf': [1, 2, 4]
}

# pipeline
pipe = ImbPipeline(steps=[
    ('prep', preprocessor),
    ('resample', TomekLinks()),
    ('clf', rf)
])

# GridSearchCV
grid_rf = GridSearchCV(
    estimator=pipe,
    param_grid={'clf__' + k: v for k, v in param_grid_rf.items()},
    cv=3,
    scoring='f1_macro',
    n_jobs=-1
)

# train
grid_rf.fit(X_train, y_train)

# best model
best_model_rf = grid_rf.best_estimator_

# predict
y_pred = best_model_rf.predict(X_test)

# evaluate
print("Test Accuracy:", best_model_rf.score(X_test, y_test))
print("Best Parameters:", grid_rf.best_params_)
print("Best CV Score:", grid_rf.best_score_)

```

ภาพภาคผนวกที่ 14 คำสั่ง GridSearchCV เพื่อหาพารามิเตอร์ Random Forest

```

best_params_rf = grid_rf.best_params_
rf = RandomForestClassifier(
    class_weight='balanced',
    criterion='gini',
    n_estimators=best_params_rf['clf_n_estimators'],
    max_depth=best_params_rf['clf_max_depth'],
    min_samples_split=best_params_rf['clf_min_samples_split'],
    min_samples_leaf=best_params_rf['clf_min_samples_leaf']
)

model_rf = ImbPipeline(steps=[
    ('prep', preprocessor),
    ('resample', TomekLinks()),
    ('clf', rf)
])

# train ใหม่
model_rf.fit(X_train, y_train)
y_pred=model_rf.predict(X_test)
print('Random Forest Performance:{:.2f}'.format(model_rf.score(X_test, y_test)))
y_pred[:10]

```

ภาพภาคผนวกที่ 15 คำสั่งสร้างตัวแบบ Random Forest และทำนายผลลัพธ์

```

from sklearn.metrics import classification_report
print(classification_report(y_test,y_pred))

rf_roc_auc = roc_auc_score(y_test, model_rf.predict_proba(X_test), multi_class="ovr", average="weighted")
print(f"Weighted ROC AUC (OVR): {rf_roc_auc:.2f}")
# คำนวณค่า fpr และ tpr สำหรับแต่ละคลาส
fpr = {}
tpr = {}
thresholds = {}
classes = model_rf.classes_
plt.figure(figsize=(8, 6))
for i, c in enumerate(classes):
    # สร้าง ROC curve สำหรับแต่ละคลาส
    fpr[c], tpr[c], thresholds[c] = roc_curve(y_test == c, model_rf.predict_proba(X_test)[:, i])
    plt.plot(fpr[c], tpr[c], label=f'Class {c} (area = {roc_auc_score(y_test == c, model_rf.predict_proba(X_test)[:, i]):.2f})')
# Plot settings
plt.plot([0, 1], [0, 1], 'r--')
plt.xlim([0.0, 1.0])
plt.ylim([0.0, 1.05])
plt.xlabel('False Positive Rate')
plt.ylabel('True Positive Rate')
plt.title('Receiver Operating Characteristic of Random Forest Performance (ROC) Curve')
plt.legend(loc="lower right")
plt.savefig('Log_Roc')
plt.show()

```

ภาพภาคผนวกที่ 16 คำสั่งตรวจสอบประสิทธิภาพ Random Forest

```

clf = model_rf.named_steps['clf']
feature_names = model_rf.named_steps['prep'].get_feature_names_out()

importance = clf.feature_importances_

df_imp = pd.DataFrame({
    'feature_full': feature_names,
    'importance': importance
})

def original_name(x):
    x = x.replace("num__", "").replace("cat__", "")
    return x.split("__")[0]

df_imp['feature'] = df_imp['feature_full'].apply(original_name)

feature_importance = df_imp.groupby('feature')['importance'].sum()
feature_importance = feature_importance.sort_values(ascending=False)

cmap = plt.get_cmap("coolwarm")
norm = plt.Normalize(
    vmin=feature_importance.min(),
    vmax=feature_importance.max()
)

plt.figure(figsize=(10,6))
ax = plt.gca()

bars = ax.bar(
    feature_importance.index,
    feature_importance.values,
    color=cmap(norm(feature_importance.values))
)

for bar in bars:
    height = bar.get_height()
    ax.text(
        bar.get_x() + bar.get_width()/2,
        height,
        f'{height:.3f}',
        ha='center',
        va='bottom',
        fontsize=10
    )

plt.title("Feature Importance from Random Forest")
plt.xlabel("Variables")
plt.ylabel("Importance")

sm = plt.cm.ScalarMappable(cmap=cmap, norm=norm)
sm.set_array([])

cbar = plt.colorbar(sm, ax=ax)
cbar.set_label("Importance")

plt.xticks(rotation=45, ha='right')
plt.tight_layout()
plt.show()

```

ภาพภาคผนวกที่ 17 คำสั่ง Feature Importance ของ Random Forest

```

# Grid Searchcv
svm = SVC(
    class_weight='balanced',
    probability=True
)

# parameter grid
param_grid_svm = {
    'C': [0.1, 1, 10, 100],
    'kernel': ['linear', 'rbf', 'poly'],
    'gamma': ['scale', 'auto']
}

# pipeline
pipe = ImbPipeline(steps=[
    ('prep', preprocessor),
    ('resample', TomekLinks()),
    ('clf', svm)
])

# Grid Search
grid_svm = GridSearchCV(
    estimator=pipe,
    param_grid={'clf__' + k: v for k, v in param_grid_svm.items()},
    cv=3,
    scoring='f1_macro',
    n_jobs=-1
)

# train
grid_svm.fit(X_train, y_train)

# best model
best_model_svm = grid_svm.best_estimator_

# prediction
y_pred = best_model_svm.predict(X_test)

print("Test Accuracy:", best_model_svm.score(X_test, y_test))
print("Best Parameters:", grid_svm.best_params_)
print("Best CV Score:", grid_svm.best_score_)

```

ภาพภาคผนวกที่ 18 คำสั่ง GridSearchCV เพื่อหาพารามิเตอร์ Support Vector Machine


```
best_params_svm = grid_svm.best_params_
svm = SVC(
    C=best_params['clf__C'],
    kernel=best_params['clf__kernel'],
    gamma=best_params['clf__gamma'],
    class_weight='balanced',
    probability=True
)
```

```
model_svm = ImbPipeline([
    ('prep', preprocessor),
    ('resample', TomekLinks()),
    ('clf', svm)
])
model_svm.fit(X_train, y_train)
```

```
y_pred = model_svm.predict(X_test)
print('Accuracy of Support Vector Machine:{:.2f}'.format(model_svm.score(X_test,y_test)))
```

ภาพภาคผนวกที่ 19 คำสั่งสร้างตัวแบบ Support Vector Machine และทำนายผลลัพธ์

```
from sklearn.metrics import classification_report
print(classification_report(y_test,y_pred))
```

```
# คำนวณ ROC AUC โดยใช้ OvR (One-vs-Rest)
svm_roc_auc = roc_auc_score(y_test, model_svm.predict_proba(X_test), multi_class="ovr", average="weighted")
print(f"Weighted ROC AUC (OvR): {svm_roc_auc:.2f}")

# คำนวณค่า fpr และ tpr สำหรับแต่ละคลาส
fpr = {}
tpr = {}
thresholds = {}
classes = model_svm.classes_

plt.figure(figsize=(8, 6))

for i, c in enumerate(classes):
    # สร้าง ROC curve สำหรับแต่ละคลาส
    fpr[c], tpr[c], thresholds[c] = roc_curve(y_test == c, model_svm.predict_proba(X_test)[:, i])
    plt.plot(fpr[c], tpr[c], label=f'Class {c} (area = {roc_auc_score(y_test == c, model_svm.predict_proba(X_test)[:, i]):.2f})')

# การตั้งค่ากราฟ
plt.plot([0, 1], [0, 1], 'r--')
plt.xlim([0.0, 1.0])
plt.ylim([0.0, 1.05])
plt.xlabel('False Positive Rate')
plt.ylabel('True Positive Rate')
plt.title('Receiver Operating Characteristic of Support Vector Machine(ROC) Curve')
plt.legend(loc="lower right")
plt.savefig('Log_Roc')
plt.show()
```

ภาพภาคผนวกที่ 20 คำสั่งตรวจสอบประสิทธิภาพ Support Vector Machine

```

from sklearn.inspection import permutation_importance
# ใช้ feature คำนวณ
result = permutation_importance(model_svm,X_test,y_test,scoring="accuracy",n_repeats=10)
# แปลงผลลัพธ์เป็น DataFrame
feature_importance = pd.Series(result.importances_mean,index=X.columns)
# เรียงลำดับจากมากไปน้อย
feature_importance = feature_importance.sort_values(ascending=False)
# สร้างสีไล่ระดับจาก colormap
cmap = plt.get_cmap("coolwarm")
norm = plt.Normalize(
    vmin=feature_importance.min(),
    vmax=feature_importance.max()
)
# สร้างกราฟ barplot
plt.figure(figsize=(10, 6))
ax = plt.gca()
bars = ax.bar(
    feature_importance.index,
    feature_importance.values,
    color=cmap(norm(feature_importance.values))
)
# เพิ่ม title และ labels
plt.title("Feature Importance from SVM (Permutation Importance)")
plt.xlabel("Features")
plt.ylabel("Importance")

# เพิ่มตัวเลขบนกราฟ (เหมือน ANN)
for bar in bars:
    height = bar.get_height()
    ax.text(
        bar.get_x() + bar.get_width()/2,
        height,
        f'{height:.3f}',
        ha='center',
        va='bottom',
        fontsize=10
    )
# เพิ่ม colorbar
sm = plt.cm.ScalarMappable(cmap=cmap, norm=norm)
sm.set_array([])

cbar = plt.colorbar(sm, ax=ax)
cbar.set_label('Importance')

plt.xticks(rotation=45, ha="right")
plt.tight_layout()
plt.show()

```

ภาพภาคผนวกที่ 21 คำสั่ง Feature Importance ของ Support Vector Machine

```

from sklearn.neural_network import MLPClassifier
# กำหนดพารามิเตอร์ที่ต้องการลองใน GridSearchCV
ann = MLPClassifier(
    max_iter=1000
)

# parameter grid
param_grid_ann = {
    'hidden_layer_sizes': [(50,), (100,), (150,), (100, 100)],
    'activation': ['tanh', 'relu'],
    'alpha': [0.001, 0.01, 0.1],
    'solver': ['adam', 'sgd']
}

# pipeline
pipe = ImbPipeline(steps=[
    ('prep', preprocessor),
    ('resample', TomekLinks()),
    ('clf', ann)
])

# Grid Search
grid_ann = GridSearchCV(
    estimator=pipe,
    param_grid={'clf__' + k: v for k, v in param_grid_ann.items()},
    cv=3,
    scoring='f1_macro',
    n_jobs=-1
)

# train
grid_ann.fit(X_train, y_train)

# best model
best_model_ann = grid_ann.best_estimator_

# prediction
y_pred = best_model_ann.predict(X_test)

print("Test Accuracy:", best_model_ann.score(X_test, y_test))
print("Best Parameters:", grid_ann.best_params_)
print("Best CV Score:", grid_ann.best_score_)

```

ภาพภาคผนวกที่ 22 คำสั่ง GridSearchCV เพื่อหาพารามิเตอร์ Artificial Neural Network

```

best_params_ann = grid_ann.best_params_
ann = MLPClassifier(
    hidden_layer_sizes=best_params_ann['clf__hidden_layer_sizes'],
    activation=best_params_ann['clf__activation'],
    alpha=best_params_ann['clf__alpha'],
    solver=best_params_ann['clf__solver'],
    max_iter=1000
)

model_ann = ImbPipeline(steps=[
    ('prep', preprocessor),
    ('resample', TomekLinks()),
    ('clf', ann)
])

model_ann.fit(X_train, y_train)
y_pred = model_ann.predict(X_test)
print('Accuracy of Artificial Neural Network: {:.2f}'.format(model_ann.score(X_test, y_test)))

```

ภาพภาคผนวกที่ 23 คำสั่งสร้างตัวแบบ Artificial Neural Network และทำนายผลลัพธ์

```

from sklearn.metrics import classification_report
print(classification_report(y_test, y_pred))

# ตรวจสอบว่ามี predict_proba หรือไม่
if hasattr(model_ann, "predict_proba"):
    y_score = model_ann.predict_proba(X_test) # ค่าความน่าจะเป็นของแต่ละ class
    # คำนวณ Weighted ROC AUC (OvR)
    dt_roc_auc = roc_auc_score(y_test, y_score, multi_class="ovr", average="weighted")
    print(f"Weighted ROC AUC (OvR): {dt_roc_auc:.2f}")

    # คำนวณค่า fpr และ tpr สำหรับแต่ละคลาส
    fpr = {}
    tpr = {}
    thresholds = {}
    classes = model_ann.classes_

    plt.figure(figsize=(8, 6))

    for i, c in enumerate(classes):
        # สร้าง ROC curve สำหรับแต่ละคลาส
        fpr[c], tpr[c], thresholds[c] = roc_curve(y_test == c, y_score[:, i])
        plt.plot(fpr[c], tpr[c], label=f'Class {c} (area = {roc_auc_score(y_test == c, y_score[:, i]):.2f})')

    # การตั้งค่ากราฟ
    plt.plot([0, 1], [0, 1], 'r--')
    plt.xlim([0.0, 1.0])
    plt.ylim([0.0, 1.05])
    plt.xlabel('False Positive Rate')
    plt.ylabel('True Positive Rate')
    plt.title('Receiver Operating Characteristic of ann (ROC) Curve')
    plt.legend(loc="lower right")
    plt.savefig('ANN_Roc')
    plt.show()
else:
    print("โมเดล Neural Network ไม่รองรับ predict_proba()")

```

ภาพภาคผนวกที่ 24 คำสั่งตรวจสอบประสิทธิภาพ Artificial Neural Network

```

from sklearn.inspection import permutation_importance
# คำนวณ Permutation Importance
result = permutation_importance(model_ann, X_test, y_test, scoring="accuracy", n_repeats=10)
# แปลงผลลัพธ์เป็น DataFrame
feature_importance = pd.Series(result.importances_mean, index=X.columns)
# เรียงลำดับจากมากไปน้อย
feature_importance = feature_importance.sort_values(ascending=False)
# สร้างสีไล่ระดับจาก colormap
cmap = plt.get_cmap("coolwarm")
norm = plt.Normalize(
    vmin=feature_importance.min(),
    vmax=feature_importance.max()
)
# plot
plt.figure(figsize=(10, 6))
ax = plt.gca()

bars = ax.bar(
    feature_importance.index,
    feature_importance.values,
    color=cmap(norm(feature_importance.values))
)

# เพิ่มตัวเลขบนแท่งกราฟ
for bar in bars:
    height = bar.get_height()
    ax.text(
        bar.get_x() + bar.get_width()/2,
        height,
        f'{height:.3f}',
        ha='center',
        va='bottom',
        fontsize=9
    )

# title / labels
plt.title("Feature Importance from Artificial Neural Network (Permutation)")
plt.xlabel("Features")
plt.ylabel("Importance")
# colorbar
sm = plt.cm.ScalarMappable(cmap=cmap, norm=norm)
sm.set_array([])
cbar = plt.colorbar(sm, ax=ax)
cbar.set_label('Importance')
plt.xticks(rotation=45, ha="right")
plt.tight_layout()
plt.show()

```

ภาพภาคผนวกที่ 25 คำสั่ง Feature Importance ของ Artificial Neural Network

```

knn = KNeighborsClassifier()
# parameter grid

param_grid_knn = {
    'n_neighbors': [3, 5, 7],
    'weights': ['uniform', 'distance'], # แนะนำตัวนี้
    'metric': ['euclidean', 'manhattan', 'chebyshev']
}

# pipeline
pipe = ImbPipeline(steps=[
    ('prep', preprocessor),
    ('resample', TomekLinks()),
    ('clf', knn)
])

# Grid Search
grid_knn = GridSearchCV(
    estimator=pipe,
    param_grid={'clf__' + k: v for k, v in param_grid_knn.items()},
    cv=3,
    scoring='f1_macro',
    n_jobs=-1
)

# train
grid_knn.fit(X_train, y_train)
# best model
best_model_knn = grid_knn.best_estimator_
# prediction
y_pred = best_model_knn.predict(X_test)
print("Test Accuracy:", best_model_knn.score(X_test, y_test))
print("Best Parameters:", grid_knn.best_params_)
print("Best CV Score:", grid_knn.best_score_)

```

ภาพภาคผนวกที่ 26 คำสั่ง GridSearchCV เพื่อหาพารามิเตอร์ K-Nearest Neighbors

```

knn = KNeighborsClassifier()
# parameter grid

param_grid_knn = {
    'n_neighbors': [3, 5, 7],
    'weights': ['uniform', 'distance'], # แนะนำตัวนี้
    'metric': ['euclidean', 'manhattan', 'chebyshev']
}
# pipeline
pipe = ImbPipeline(steps=[
    ('prep', preprocessor),
    ('resample', TomekLinks()),
    ('clf', knn)
])
# Grid Search
grid_knn = GridSearchCV(
    estimator=pipe,
    param_grid={'clf__' + k: v for k, v in param_grid_knn.items()},
    cv=3,
    scoring='f1_macro',
    n_jobs=-1
)
# train
grid_knn.fit(X_train, y_train)
# best model
best_model_knn = grid_knn.best_estimator_
# prediction
y_pred = best_model_knn.predict(X_test)
print("Test Accuracy:", best_model_knn.score(X_test, y_test))
print("Best Parameters:", grid_knn.best_params_)
print("Best CV Score:", grid_knn.best_score_)
y_pred = model_knn.predict(X_test)
print('Accuracy of K-Nearest Neighbors:{:.2f}'.format(model_knn.score(X_test,y_test)))

```

ภาพภาคผนวกที่ 27 คำสั่งสร้างตัวแบบ K-Nearest Neighbors และทำนายผลลัพธ์

```

from sklearn.metrics import classification_report
print(classification_report(y_test,y_pred))

knn_roc_auc = roc_auc_score(y_test, model_knn.predict_proba(X_test), multi_class='ovr', average='weighted')
print(f"Weighted ROC AUC (OvR): {knn_roc_auc:.2f}")
# คำนวณค่า fpr และ tpr สำหรับแต่ละคลาส
fpr = {}
tpr = {}
thresholds = {}
classes = model_knn.classes_
plt.figure(figsize=(8, 6))
# สร้าง ROC curve สำหรับแต่ละคลาส
for i, c in enumerate(classes):
    fpr[c], tpr[c], thresholds[c] = roc_curve(y_test == c, model_knn.predict_proba(X_test)[: , i])
    # การคำนวณ AUC สำหรับแต่ละคลาส
    class_auc = roc_auc_score(y_test == c, model_knn.predict_proba(X_test)[: , i])
    plt.plot(fpr[c], tpr[c], label=f'Class {c} (area = {class_auc:.2f})')
# การตั้งค่ากราฟ
plt.plot([0, 1], [0, 1], 'r--')
plt.xlim([0.0, 1.0])
plt.ylim([0.0, 1.05])
plt.xlabel('False Positive Rate')
plt.ylabel('True Positive Rate')
plt.title('Receiver Operating Characteristic (ROC) Curve')
plt.legend(loc="lower right")
plt.savefig('KNN_Roc')
plt.show()

```

ภาพภาคผนวกที่ 28 คำสั่งตรวจสอบประสิทธิภาพ K-Nearest Neighbors


```

from sklearn.inspection import permutation_importance
# คำนวณ Permutation Importance
result = permutation_importance(model_knn, X_test, y_test, n_repeats=10)
# แปลงผลลัพธ์เป็น DataFrame
importance_df = pd.DataFrame(result.importances_mean, index=X_train.columns, columns=["Importance"])
# เรียงลำดับความสำคัญจากมากไปน้อย
importance_df = importance_df.sort_values(by="Importance", ascending=False)
# สร้าง colormap
cmap = plt.get_cmap("coolwarm")
norm = plt.Normalize(
    vmin=feature_importance.min(),
    vmax=feature_importance.max()
)
# plot
plt.figure(figsize=(10, 6))
ax = plt.gca()

bars = ax.bar(
    feature_importance.index,
    feature_importance.values,
    color=cmap(norm(feature_importance.values))
)

# เพิ่มตัวเลขบนแท่งกราฟ
for bar in bars:
    height = bar.get_height()
    ax.text(
        bar.get_x() + bar.get_width()/2,
        height,
        f'{height:.3f}',
        ha='center',
        va='bottom',
        fontsize=9
    )

# title / labels
plt.title("Feature Importance from Artificial Neural Network (Permutation)")
plt.xlabel("Features")
plt.ylabel("Importance")
# colorbar
sm = plt.cm.ScalarMappable(cmap=cmap, norm=norm)
sm.set_array([])
cbar = plt.colorbar(sm, ax=ax)
cbar.set_label('Importance')
plt.xticks(rotation=45, ha="right")
plt.tight_layout()
plt.show()

```

ภาพภาคผนวกที่ 29 คำสั่ง Feature Importance ของ K-Nearest Neighbors

ประวัติการศึกษา และการทำงาน

ชื่อ-นามสกุล	ณัฐธินิชา เมืองมูล
วัน เดือน ปี เกิด	09 พฤษภาคม 2542
สถานที่เกิด	โรงพยาบาลศิริกิต
ที่อยู่ปัจจุบัน	98/31 งามวงศ์วาน 52 แขวง จตุจักร กรุงเทพมหานคร 10900
ประวัติการศึกษา	พ.ศ.2564 จบการศึกษาระดับปริญญาตรี คณะวิทยาศาสตร์ประยุกต์ ภาควิชาฟิสิกส์อุตสาหกรรมและอุปกรณ์การแพทย์ สาขาอุปกรณ์การแพทย์
ผลงานตีพิมพ์	1. ณัฐธินิชา เมืองมูล, จุฑาภรณ์ สันสมบูรณ์ทองและ ผกาเกษ วัฒยา (2568). ปัจจัยที่ส่งผลต่อประสิทธิภาพการรักษาโรคเนื้องอกกระดูกของผู้ป่วย (Influencing Factors with the Effectiveness of Bone Tumors Treatment in Patients). ในรายงานสืบเนื่องจากการประชุมมหาวิทยาลัยหอการค้าวิชาการระดับชาติ (The 9th UTCC National Conference “SDGs for a Better Research Future”).มหาวิทยาลัยหอการค้า. 2. ณัฐธินิชา เมืองมูล, จุฑาภรณ์ สันสมบูรณ์ทองและ ผกาเกษ วัฒยา (2569). ปัจจัยที่ส่งผลต่อประสิทธิภาพการรักษาโรคเนื้องอกกระดูกของผู้ป่วย (Influencing Factors with the Effectiveness of Bone Tumors Treatment in Patients). นำเสนอในนิทรรศการงานวิจัยของนิสิตและโครงการอุทยานการแพทย์ (KU MedAI Innovation Challenge 2026). มหาวิทยาลัยเกษตรศาสตร์